


PROPOSAL SKRIPSI

**MODEL KLASIFIKASI TUMOR OTAK PADA CITRA MRI BERBASIS
VARIAN LOCAL BINARY PATTERN DAN SUPPORT VECTOR
MACHINE DENGAN ANALISIS INTERPRETABILITAS LIME**



Andyan Yogawardhana

21/482180/PA/21030

**PROGRAM STUDI S1 ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2025

ABSTRAK

MODEL KLASIFIKASI TUMOR OTAK PADA CITRA MRI BERBASIS VARIAN LOCAL BINARY PATTERN DAN SUPPORT VECTOR MACHINE DENGAN ANALISIS INTERPRETABILITAS LIME

Oleh

Andyan Yogawardhana

21/482180/PA/21030

Tumor otak merupakan salah satu penyakit serius yang dapat berakibat fatal apabila tidak ditangani sejak dini. Magnetic Resonance Imaging (MRI) banyak digunakan sebagai media deteksi, tetapi interpretasi manual masih bergantung pada keahlian radiolog dan berisiko menimbulkan keterlambatan maupun ketidakakuratan diagnosis. Meskipun akurat, metode berbasis *deep learning* membutuhkan jumlah data besar, sumber daya komputasi dengan performa tinggi, serta arsitektur kompleks sehingga sulit diimplementasikan oleh fasilitas kesehatan di wilayah rural Indonesia untuk memperoleh diagnosis yang mudah dipahami.

Penelitian ini mengembangkan sebuah model dengan pendekatan *machine learning* sederhana untuk klasifikasi tumor otak berbasis citra MRI dengan memanfaatkan metode ekstraksi fitur tekstur Local Binary Pattern (LBP) beserta variannya serta algoritma klasifikasi Support Vector Machine (SVM). Dataset yang digunakan adalah Brain Tumor Classification (MRI) dari Kaggle dengan empat kelas, yaitu glioma, meningioma, pituitary, dan otak sehat. Komparasi performa model dilakukan terhadap beberapa algoritma *machine learning* dan *deep learning* lain. Evaluasi model dilakukan menggunakan *confusion matrix* dengan metrik *accuracy*, *precision*, *recall*, dan *F1-score*. Model SVM dengan performa terbaik akan melewati proses analisis interpretabilitas prediksi menggunakan pendekatan Explainable AI dengan teknik LIME untuk memperoleh penjelasan visual area citra yang paling berpengaruh terhadap hasil diagnosis. Penelitian ini diharapkan dapat menghasilkan model klasifikasi yang akurat, efisien, dan mudah dimengerti sehingga dapat menjadi alternatif solusi bagi fasilitas kesehatan dengan keterbatasan data maupun infrastruktur komputasi.

Kata Kunci: Klasifikasi Tumor Otak; Magnetic Resonance Imaging; Local Binary Pattern; Support Vector Machine; LIME

DAFTAR ISI

ABSTRAK.....	1
DAFTAR ISI.....	2
DAFTAR GAMBAR.....	4
DAFTAR TABEL.....	5
BAB 1 PENDAHULUAN.....	6
1.1 Latar Belakang.....	6
1.2 Rumusan Masalah.....	11
1.3 Batasan Masalah.....	11
1.4 Tujuan Penelitian.....	12
1.5 Manfaat Penelitian.....	12
1.6 Sistematika Penelitian.....	13
BAB II TINJAUAN PUSTAKA.....	14
BAB III LANDASAN TEORI.....	25
3.1 Tumor Otak.....	25
3.2 Magnetic Resonance Imaging (MRI).....	25
3.3 Pengolahan Citra Digital.....	27
3.3.1 Preprocessing.....	27
3.3.2 Ekstraksi Fitur.....	28
3.3.3 Klasifikasi.....	28
3.3.3.1 Klasifikasi Berbasis Machine Learning.....	29
3.3.3.2 Klasifikasi Berbasis Deep Learning.....	29
3.4 Artificial Intelligence (AI).....	30
3.5 Machine Learning.....	31
3.6 Local Binary Pattern (LBP).....	32
3.6.1 nLBP.....	34

3.6.2 α LBP.....	35
3.7 Support Vector Machine (SVM).....	36
3.8 Evaluasi Model.....	40
3.9 Explainable Artificial Intelligence (XAI).....	41
3.9.1 Framework XAI.....	42
3.9.1.1 Model-based dan Post Hoc Explanation.....	42
3.9.1.2 Model-specific dan Model-agnostic Explanation.....	42
3.9.1.3 Global dan Local Explanation.....	43
3.9.2 Implementasi XAI dalam Analisis Citra.....	43
3.9.2.1 Visual-based.....	44
3.9.2.2 Textual-based.....	44
3.9.2.3 Example-based.....	45
3.9.3 Local Interpretable Model-Agnostic Explanations (LIME).....	45
BAB IV METODOLOGI PENELITIAN.....	48
4.1 Desain Penelitian.....	48
4.2 Data Penelitian.....	49
4.3 Alat Penelitian.....	50
4.3.1 Laptop.....	50
4.3.2 Perangkat Lunak.....	50
4.4 Tahapan Pengembangan Model.....	50
4.4.1 Preprocessing.....	50
4.4.2 Ekstraksi Fitur.....	51
4.4.3 Klasifikasi.....	51
4.5 Evaluasi Model.....	52
4.6 Implementasi Explainable AI (XAI).....	52
BAB V JADWAL PENELITIAN.....	54
REFERENSI.....	55

DAFTAR GAMBAR

Gambar 3.1 Orientasi Proton terhadap Medan Magnet Eksternal (Azhar & Chong, 2022).....	26
Gambar 3.2 Visualisasi Skema Penentuan Variabel LBP (Ojala dkk, 2002).....	33
Gambar 3.3 Perbandingan Piksel pada Teknik nLBP (Kaplan dkk. 2020).....	35
Gambar 3.4 Penentuan Piksel pada Teknik α LBP (Kaplan dkk. 2020).....	36
Gambar 3.3 Contoh Skema Klasifikasi SVM (Cortes & Vapnik, 1995).....	37
Gambar 3.4 Transformasi Dimensi Data dengan Kernel Function (Hafshejani & Moabarfard, 2022).....	39
Gambar 3.5 Penjelasan Visual Hasil Prediksi LIME (Ribeiro dkk., 2016).....	47
Gambar 4.2 Contoh Citra Sampel Dataset (Bhuvaji dkk., 2025).....	50

DAFTAR TABEL

Tabel 2.1 Tinjauan Pustaka.....	22
Tabel 3.1 Contoh Fungsi Kernel (Azzeh dkk. 2022).....	38
Tabel 3.2 Contoh Hasil Evaluasi Confusion Matrix (Yang dkk., 2021).....	40
Tabel 3.3 Klasifikasi Framework Teknik XAI (Van Der Velden dkk., 2022).....	43
Tabel 5.1 Jadwal Penelitian.....	54

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Otak merupakan bagian dari *central nervous system* (CNS) atau sistem saraf pusat, sekaligus menjadi salah satu organ tubuh terpenting yang bertugas untuk mengatur dan mengendalikan sebagian besar fungsi penting tubuh manusia (National Cancer Institute, 2023). Gangguan maupun kerusakan pada sistem saraf pusat dapat mengganggu fungsi vital yang dimiliki organ tersebut sehingga mampu memberikan dampak yang signifikan bagi kesehatan dan kehidupan seseorang. Salah satu kelainan yang dapat menyerang otak sebagai bagian dari sistem saraf pusat adalah tumor (Özkaraca dkk., 2023). Tumor otak adalah sebuah kelainan seluler yang ditandai dengan pembentukan, pertumbuhan, atau akumulasi sel secara tidak normal di bagian otak dengan karakteristik yang beragam berdasarkan jenis dan tingkat keganasannya (Basthikodi dkk., 2024). Penyakit tumor otak pada bagian tubuh manusia menjadi salah satu kondisi medis yang perlu mendapatkan perhatian serius karena berpotensi besar memberikan dampak yang fatal terhadap para penderitanya, mulai dari penurunan kualitas hidup hingga risiko kematian. Berdasarkan data yang diperoleh dari Global Cancer Observatory di tahun 2022, dari total 5.738 kasus penyakit tumor otak yang terdiagnosis di Indonesia, angka kematian yang ditunjukkan mencapai 5.259 jiwa, yaitu lebih dari 91% dari kasus terdiagnosis (Ferlay dkk., 2024). Tingginya persentase kematian ini menunjukkan bahwa upaya penanganan dini sangat diperlukan agar tenaga medis dapat memberikan tindakan atau penanganan klinis yang lebih cepat dan tepat. Dengan adanya penanganan dini tersebut, diharapkan mampu meningkatkan peluang kesembuhan pasien sekaligus menekan persentase korban meninggal akibat penyakit ini.

Penanganan penyakit tumor otak dapat dilakukan melalui berbagai cara, terlebih lagi melalui inovasi teknologi pencitraan medis yang membuka banyak peluang untuk memanfaatkannya sebagai alat bantu diagnosis. Metode pencitraan yang sering digunakan adalah dengan bantuan citra Magnetic Resonance Imaging (MRI) yang mampu menampilkan informasi mendetail tentang anatomi tubuh

manusia tanpa perlu melewati prosedur invasif (Liu, 2019). Citra MRI dapat memberikan informasi penting tentang kondisi kesehatan di bagian tubuh tertentu, seperti stroke, demensia, serta tumor yang ada pada otak seseorang sehingga dapat digunakan sebagai media utama dalam proses deteksi dan diagnosis penyakit. Meskipun demikian, proses diagnosis penyakit yang memanfaatkan citra MRI secara tradisional masih bergantung pada keahlian analisis tenaga medis. Metode ini juga memiliki beberapa kekurangan, seperti membutuhkan waktu yang panjang dan tenaga yang besar, berpotensi menimbulkan perbedaan hasil analisis antara pengamat satu dengan yang lainnya, serta memungkinkan adanya ketidakakuratan interpretasi citra (Bhattacharjee dkk., 2022). Oleh karena itu, pemanfaatan pengolahan citra medis secara digital dengan bantuan komputer menjadi salah satu upaya yang penting karena dapat membantu menangani keterbatasan tersebut dengan memaksimalkan kecepatan dan ketepatan diagnosis serta memberikan hasil analisis yang dapat menjadi bahan pertimbangan tambahan dalam pengambilan keputusan tenaga medis.

Salah satu implementasi pengolahan citra medis dapat dilakukan melalui metode penglihatan komputer atau *computer vision* yang dikombinasikan dengan teknik pembelajaran mesin atau *machine learning*. Teknik tersebut menghasilkan sebuah model yang dapat memproses dan menganalisis data citra MRI untuk melakukan diagnosis berdasarkan fitur-fitur yang ada pada citra tersebut. Penelitian yang dilakukan oleh Seetha dan Raja (2018) menunjukkan bahwa sistem diagnosis penyakit tumor otak berbasis citra MRI dengan bantuan komputer menunjukkan hasil yang menjanjikan. Model berbasis *deep learning* yang dikembangkan pada penelitian tersebut dapat melakukan tugas klasifikasi dengan tingkat akurasi yang tinggi, yaitu sebesar 97.5% melalui model dengan arsitektur Convolutional Neural Network (CNN) yang umum digunakan untuk menganalisis data citra. Namun demikian, untuk dapat mencapai tingkat akurasi yang tinggi, arsitektur *deep learning* khususnya CNN tersebut membutuhkan sumber daya komputasi yang besar, waktu pelatihan yang lama, serta perangkat keras dengan performa dan spesifikasi yang tinggi seperti Graphics Processing Unit (GPU) (Sze dkk., 2017). Selain itu, jumlah data yang dibutuhkan dalam

tahap pembangunan model juga relatif besar untuk dapat memperoleh angka akurasi yang optimal sekaligus menghindari kasus *overfitting* selama proses pelatihan. Dari sisi proses pengambilan keputusan dan perolehan hasil komputasi, arsitektur CNN yang kompleks juga memiliki mekanisme pengambilan keputusan yang tidak mudah untuk dipahami secara langsung oleh manusia atau biasa disebut dengan *black-box* (Adadi & Berrada, 2018). bidang kesehatan, keterbatasan tersebut menjadi salah satu faktor krusial yang perlu diperhatikan karena model prediksi sebagai pendukung tenaga medis perlu memiliki arsitektur dengan kemudahan interpretasi serta alasan diagnosis yang kuat dan logis untuk dapat dipertanggungjawabkan dalam pengambilan hasil diagnosis penyakit pasien.

Meskipun dapat menghasilkan performa klasifikasi yang tinggi, model berbasis *deep learning* masih memiliki beberapa kekurangan seperti yang telah dijelaskan sebelumnya. Kekurangan terkait dengan besarnya kebutuhan ketersediaan data dan sumber daya komputasi ini sehubungan dengan penelitian yang dilakukan oleh Aisyah dkk. (2024). Penelitian tersebut menemukan bahwa tingkat kematangan teknologi informasi dan komunikasi atau *information and communication technology* (ICT) dari fasilitas kesehatan di Indonesia masih belum terdistribusi dengan baik. Secara umum, fasilitas kesehatan di wilayah urban atau perkotaan masih lebih unggul dan layak jika dibandingkan dengan fasilitas kesehatan yang ada di wilayah rural atau pelosok. Ketimpangan tersebut dilihat dari sisi sumber daya manusia, integrasi aplikasi atau sistem informasi, ketersediaan perangkat, serta kelayakan infrastruktur. Kondisi ini membuka peluang kepada metode alternatif selain *deep learning* yang lebih sederhana untuk dapat memiliki sistem yang tetap optimal meskipun dihadapkan dengan keterbatasan tersebut.

Dalam kasus pengembangan sistem diagnosis citra tumor otak, metode ekstraksi fitur sederhana dan algoritma klasifikasi tradisional masih relevan untuk dikembangkan, terutama sebagai salah satu alternatif untuk menghadapi permasalahan keterbatasan infrastruktur, seperti sumber daya komputasi dan data yang terbatas. Salah satu metode ekstraksi fitur yang dapat memperoleh representasi pola tekstur citra adalah Local Binary Pattern (LBP) yang

dikembangkan oleh Ojala dkk. (2002). Metode ini memiliki keunggulan dari sisi komputasi yang cepat dan ringan hingga ketahanan terhadap variasi pencahayaan dan rotasi citra. Pemilihan algoritma klasifikasi yang sesuai dengan metode ekstraksi fitur yang digunakan juga penting untuk dapat memaksimalkan performa model yang dihasilkan. Dalam hal ini, Support Vector Machine (SVM) adalah salah satu algoritma klasifikasi *machine learning* sederhana yang dapat dikombinasikan dengan LBP untuk memperoleh model klasifikasi yang optimal. SVM diperkenalkan oleh Cortes dan Vapnik (1995) melalui sebuah penelitian dengan judul *Support-Vector Networks* yang berisi penjelasan tentang cara kerja SVM dalam melakukan pemisahan dua kelas data melalui *hyperplane* di antara dua *support vectors* dari kelas yang berbeda dengan *margin* maksimum. Algoritma SVM dapat melakukan tugas analisis dan klasifikasi dengan sumber daya komputasi yang ringan serta menghasilkan performa yang baik saat jumlah data yang digunakan terbatas (Yang dkk., 2021). Dengan demikian, kombinasi metode ekstraksi fitur LBP dan algoritma klasifikasi SVM tersebut diharapkan dapat menghasilkan sistem diagnosis tumor otak yang sederhana, efisien, dan akurat, serta dapat mengatasi permasalahan yang muncul pada model berbasis *deep learning*.

Artificial intelligence (AI), termasuk di dalamnya *machine learning* dan *deep learning* menjadi salah satu topik yang populer dalam peran perkembangan teknologi melalui kemampuan modelnya dalam melakukan tugas-tugas pengenalan pola hingga prediksi dengan akurat di berbagai sektor (Murdoch dkk., 2019). Namun, di samping performa model yang baik untuk membantu menyelesaikan permasalahan teknis, alur dan proses komputasi suatu model dalam mengambil suatu kesimpulan juga perlu untuk dapat dipahami dengan baik oleh manusia. Hal ini perlu menjadi perhatian khususnya pada model yang masih memiliki permasalahan *black-box*, yaitu kesulitan suatu model dalam menjelaskan dengan mudah tentang perubahan dan proses pengolahan data *input* menjadi *output* hasil prediksi (Adadi & Berrada, 2018). Sebuah model memerlukan tingkat interpretabilitas dan transparansi terhadap arsitektur dan mekanisme internal yang baik sehingga mampu meningkatkan kepercayaan dari sisi penggunanya. Hal

tersebut menjadi perhatian bagi berbagai sektor layanan yang mengimplementasikan model-model AI, terutama dari sektor medis dalam penanganan kasus-kasus diagnosis penyakit pasien yang membutuhkan justifikasi klinis yang kuat (Van Der Velden dkk., 2022). Oleh karena itu, salah satu solusi untuk mengatasi permasalahan *black-box* tersebut sekaligus untuk memperkuat landasan argumen dari pertanggungjawaban keputusan yang diambil oleh manusia adalah melalui implementasi Explainable AI (XAI). XAI menyediakan *framework* dan metode analisis yang dapat mengungkap alasan di balik hasil prediksi dari suatu model serta memberikan penjelasan yang dapat dipahami manusia dengan lebih mudah sehingga mampu meningkatkan transparansi, tingkat kepercayaan, serta memperkuat pertanggungjawaban diagnosis dalam konteks medis. Salah satu metode yang dapat digunakan adalah Local Interpretable Model-Agnostic Explanation (LIME) dengan inti algoritma adalah pencarian model *interpretable* lokal untuk melakukan aproksimasi perilaku model asli di sekitar suatu hasil prediksi (Ribeiro dkk., 2016). Pada data citra, LIME menentukan gabungan piksel dalam suatu wilayah atau *superpixel* mana saja yang paling berpengaruh pada hasil prediksi kelas suatu data dan menyajikan hasil analisis tersebut melalui penjelasan visual yang dapat dengan mudah dipahami oleh manusia.

Berdasarkan permasalahan tersebut, dapat disimpulkan bahwa penanganan dini pasien tumor otak menjadi salah satu upaya yang sangat penting untuk dapat dilakukan secara cepat, tepat, dan akurat. Dalam rangka mendukung upaya tersebut, penggunaan sistem diagnosis penyakit dengan bantuan komputer berdasarkan hasil pemindaian citra MRI menjadi salah satu upaya yang mampu meningkatkan peluang keselamatan pasien. Walaupun dapat mencapai performa dan akurasi yang tinggi, metode diagnosis penyakit yang telah dikembangkan mengimplementasikan arsitektur CNN yang memiliki beberapa keterbatasan untuk dapat diimplementasikan oleh fasilitas kesehatan yang belum memiliki infrastruktur dan perangkat komputasi yang memadai. Oleh karena itu, penelitian ini berfokus pada pengembangan model yang lebih sederhana menggunakan LBP sebagai ekstraksi fitur dan SVM sebagai algoritma klasifikasi. Kombinasi metode ini harapannya dapat mengisi celah dan melengkapi kekurangan pada model dari

penelitian sebelumnya dengan menyediakan sistem diagnosis yang tidak membutuhkan data dalam jumlah besar, waktu klasifikasi sistem yang cepat, dan sumber daya komputasi yang ringan. Selain kebutuhan dari sisi komputasi yang lebih efisien daripada model berbasis *deep learning*, model tersebut juga diharapkan dapat menghasilkan performa dan akurasi diagnosis yang cukup baik dan kompetitif sehingga dapat membantu upaya penanganan pasien serta dapat menjadi bahan evaluasi tambahan bagi tenaga medis, terlebih lagi pada fasilitas-fasilitas kesehatan di Indonesia yang masih mengalami kendala persediaan data dan keterbatasan sumber daya. Di samping itu, melalui implementasi XAI, harapannya model yang dibangun dapat memiliki tingkat transparansi arsitektur dan interpretabilitas yang baik. LIME digunakan sebagai algoritma pencarian alasan pengambilan keputusan diagnosis suatu sampel data dari sebuah model melalui penjelasan visual yang dapat dipahami manusia dengan mudah. Dengan demikian, model tersebut harapannya mampu memberikan hasil diagnosis yang akurat dan disertai dengan alasan prediksi yang dapat dipahami oleh tenaga medis sehingga dapat meningkatkan kepercayaan dalam mengambil keputusan klinis serta memperkuat pertanggungjawaban diagnosis.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, penelitian ini merumuskan permasalahan terkait dengan keterbatasan yang masih ditemukan pada model diagnosis atau klasifikasi penyakit tumor otak manusia berdasarkan citra MRI yang menggunakan basis *deep learning*. Model tersebut umumnya masih memerlukan kebutuhan jumlah data yang besar dan sumber daya komputasi dengan performa yang tinggi sehingga kurang sesuai untuk diimplementasikan pada fasilitas kesehatan di wilayah rural Indonesia yang masih memiliki ketersediaan infrastruktur yang terbatas. Selain itu, tingkat interpretabilitas arsitektur *deep learning* yang relatif rendah menyebabkan proses klasifikasi atau diagnosis penyakit sulit dijelaskan secara transparan sehingga kurang mampu mendukung pertanggungjawaban medis.

1.3 Batasan Masalah

Batasan masalah yang ditetapkan pada penelitian ini adalah sebagai berikut:

1. Objek yang digunakan pada penelitian ini adalah citra MRI otak manusia, yaitu dataset publik yang bersumber dari Kaggle dengan judul Brain Tumor Classification (MRI) dan diunggah oleh Bhuvaji dkk. (2025).
2. Metode dan algoritma yang digunakan dalam proses pengembangan model adalah Local Binary Pattern (LBP) klasik dengan variannya, nLBP dan α LBP, dan MB-LBP untuk ekstraksi fitur tekstur dan Support Vector Machine (SVM) untuk klasifikasi dengan kategori *multiclass*.
3. Performa klasifikasi SVM dibandingkan dengan model *machine learning* k-Nearest Neighbor, Decision Tree, Random Forest, dan Naive Bayes serta model *deep learning* CNN.
4. Implementasi Explainable AI menggunakan teknik Local Interpretable Model-Agnostic Explanations (LIME) terhadap model SVM dengan performa terbaik.

1.4 Tujuan Penelitian

Tujuan dari dilakukannya penelitian ini adalah untuk mengembangkan model *machine learning* yang dapat membantu proses diagnosis penyakit tumor otak manusia. Model tersebut mengimplementasikan metode LBP untuk melakukan ekstraksi fitur tekstur dari citra MRI dan algoritma SVM untuk mengolah data hasil ekstraksi fitur dan mengklasifikasikan hasil diagnosis ke dalam empat kategori tumor otak. Model yang berhasil dibangun akan dianalisis menggunakan *framework* XAI dengan teknik LIME untuk meningkatkan interpretabilitas, khususnya menemukan alasan diagnosis penyakit.

1.5 Manfaat Penelitian

Penelitian ini dilakukan dengan harapan agar dapat memberikan manfaat dan kontribusi secara ilmiah dengan membantu tenaga medis dan akademisi dalam mempelajari metode-metode *machine learning*, khususnya dalam lingkup penglihatan komputer dan klasifikasi citra medis. Selain itu, hasil model klasifikasi yang diperoleh dari penelitian ini juga diharapkan dapat

diimplementasikan secara langsung untuk membantu tenaga medis dalam melakukan upaya diagnosis dini dari penyakit tumor otak pada pasien secara akurat, efisien, dan dapat dipercaya.

1.6 Sistematika Penelitian

Naskah laporan pada proposal penelitian ini akan disusun berdasarkan sistematika berikut:

BAB I PENDAHULUAN

Bab ini berisi uraian tentang latar belakang penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, dan sistematika penelitian.

BAB II TINJAUAN PUSTAKA

Bab ini berisi tinjauan pustaka dan pemaparan tentang penelitian-penelitian terdahulu yang relevan dengan topik klasifikasi citra tumor otak manusia.

BAB III LANDASAN TEORI

Bab ini berisi penjelasan teori-teori yang digunakan sebagai dasar acuan implementasi metodologi yang digunakan selama proses penelitian dan pengembangan model klasifikasi.

BAB IV METODOLOGI PENELITIAN

Bab ini berisi rincian metode yang digunakan serta tahapan yang dilakukan pada penelitian klasifikasi citra tumor otak dari tahap pengumpulan data hingga pengembangan model.

BAB V JADWAL PENELITIAN

Bab ini berisi rincian jadwal pelaksanaan setiap tahapan penelitian yang akan dilakukan, khususnya dalam bentuk matriks perencanaan penelitian dimulai dari tinjauan pustaka, pelaksanaan, hingga penyusunan laporan penelitian.

BAB II

TINJAUAN PUSTAKA

Pada kasus diagnosis penyakit tumor otak, beberapa penelitian telah dilakukan untuk mengembangkan suatu model yang dapat melakukan tugas deteksi maupun klasifikasi. Berbagai metode *computer vision* yang memanfaatkan algoritma-algoritma *deep learning* maupun *machine learning* juga telah dilakukan untuk mengolah citra MRI yang utamanya digunakan untuk menganalisis keberadaan tumor pada otak manusia. Salah satu metode yang sering digunakan untuk menangani permasalahan tersebut adalah Convolutional Neural Network (CNN) yang berbasis *deep learning*. Penelitian terdahulu yang mengimplementasikan metode CNN untuk mengatasi permasalahan diagnosis tumor otak dengan bantuan computer-aided diagnostic (CAD) terotomasi salah satunya telah dilakukan oleh Özkaraca dkk. (2023). Penelitian tersebut mengembangkan dan membandingkan beberapa arsitektur berbasis *deep learning* populer, yaitu Basic CNN, VGG16 Net, dan DenseNet, serta mengajukan sebuah model dengan arsitektur baru, yaitu Modified CNN yang dikembangkan untuk mengatasi kekurangan dan meningkatkan performa dari ketiga model sebelumnya. Pengembangan semua model tersebut menggunakan hasil kombinasi dataset yang diperoleh dari Kaggle, yaitu figshare, SARTAJ dataset, dan Br35H. Dengan total data sebanyak 7.021 citra Magnetic Resonance Imaging (MRI) otak manusia, dataset terbagi menjadi 4 kelas, yaitu *glioma*, *meningioma*, *pituitary*, dan otak sehat. Arsitektur baru dibangun dengan menggunakan arsitektur CNN dan meningkatkan jumlah layernya, menggunakan layer *dense* dengan intensitas yang tinggi pada tahap *preprocessing*, tidak menggunakan metode *transfer learning*, serta meningkatkan jumlah data pelatihan dengan augmentasi. Tahap validasi performa model dilakukan dengan mengimplementasikan teknik *k-fold cross validation* dengan metrik evaluasi yang digunakan adalah *accuracy*, *precision*, *recall*, dan *F1-score*. Model Arsitektur Modified CNN yang diajukan berhasil melakukan klasifikasi citra MRI dengan nilai rata-rata *F1-score* yang tinggi, yaitu sebesar 97%, lebih baik dibandingkan dengan ketiga arsitektur sebelumnya, yaitu 92% untuk Basic CNN, 86% untuk VGG16 Net, serta 85% untuk DenseNet.

Model yang dihasilkan dari penelitian tersebut memiliki beberapa kelebihan, di antaranya adalah performa klasifikasi arsitektur Modified CNN yang diajukan dapat diandalkan untuk diagnosis citra MRI tumor otak dengan nilai akurasi dan *F1-score* yang tinggi dan dapat mengatasi kekurangan yang ada pada ketiga arsitektur lain. Namun, model yang dibangun pada penelitian tersebut masih memiliki beberapa kekurangan, seperti dibutuhkan sumber daya komputasi dengan performa yang tinggi untuk menangani besarnya jumlah parameter, waktu komputasi yang dibutuhkan untuk proses pelatihan lama, dan juga arsitektur yang dibangun memiliki layer yang kompleks dan membutuhkan data dalam jumlah besar untuk menghindari overfitting.

Penelitian serupa yang menggunakan arsitektur CNN dalam kasus klasifikasi penyakit tumor otak juga pernah dilakukan oleh Sinaga dkk. (2025) yang bertujuan untuk mengatasi permasalahan keterbatasan klasifikasi dan interpretasi manual dari citra MRI tumor otak yang membutuhkan keahlian khusus dan rentan terhadap kesalahan diagnosis. Dataset yang digunakan bersumber dari Kaggle dan memiliki jumlah yang cukup besar sekaligus variatif, yaitu sejumlah 72 data citra MRI yang terbagi menjadi empat kelas seperti pada penelitian sebelumnya, yaitu otak *normal*, *meningioma*, *glioma*, dan *pituitary*. Dataset juga akan melewati tahap *preprocessing*, yaitu *grayscale*, *resizing*, dan normalisasi dengan tambahan augmentasi untuk data pelatihan. Usulan model CNN berbentuk sekuensial sederhana yang terdiri dari *layer* konvolusi, *pooling*, *dense*, dan *dropout* dengan *optimizer* Adam. Inovasi utama pada penelitian tersebut adalah usaha untuk meningkatkan interpretabilitas model dengan mengimplementasikan konsep Explainable AI (XAI) melalui visualisasi, meskipun metode XAI yang digunakan belum dijelaskan secara rinci. Nilai akurasi yang dihasilkan dari model yang dikembangkan sebesar 96% dengan performa generalisasi dan interpretabilitas yang baik. Kedua penelitian tersebut menunjukkan bahwa model yang mengimplementasikan arsitektur CNN dapat menyelesaikan permasalahan klasifikasi citra MRI tumor otak dengan baik sehingga memiliki potensi besar untuk dapat membantu mengoptimalkan proses diagnosis tenaga medis. Performa yang baik dari arsitektur CNN dapat diperoleh

dengan membutuhkan data dan sumber daya yang besar serta waktu yang lama sehingga diperlukan adanya metode alternatif yang lebih efisien untuk dapat mengatasi keterbatasan tersebut.

Selain klasifikasi, metode berbasis *deep learning* juga dapat digunakan untuk melakukan segmentasi citra. Arsitektur U-Net yang merupakan turunan dari CNN mampu melakukan tugas segmentasi citra, seperti pada penelitian yang dilakukan oleh Dhamara dkk. (2025) yang mengangkat permasalahan segmentasi citra MRI tumor otak manusia. Penelitian ini bertujuan untuk mengevaluasi performa model terhadap data klinis asli serta menganalisis pengaruh variasi *hyperparameter* yang digunakan selama tahap pelatihan model. Dataset yang digunakan bersumber dari data asli lokal yang diambil dari Rumah Sakit Islam Jakarta Cempaka Putih dengan total 3.064 citra dalam orientasi axial, coronal, dan sagittal. Setiap citra juga telah memiliki label *mask* sebagai *ground truth*. Pada *preprocessing*, dilakukan *grayscale*, normalisasi, dan augmentasi dengan *flipping* horizontal dan vertikal, *zooming*, serta penyesuaian brightness. Model U-Net yang digunakan terdiri dari bagian *encoder* untuk ekstraksi fitur dan *decoder* untuk rekonstruksi citra segmentasi. Pada tahap pelatihan menggunakan GPU, parameter *learning rate* dan *epoch* dioptimasi untuk memperoleh hasil segmentasi yang paling akurat. Evaluasi kuantitatif model dilakukan menggunakan metrik *Dice Coefficient*, *Intersection over Union* (IoU), dan *Binary Cross-Entropy Loss* serta evaluasi kualitatif melalui visualisasi. Performa model yang diperoleh memiliki konfigurasi terbaik dengan *epoch* 100 pada *learning rate* $1e^{-4}$ yang menghasilkan nilai *dice* 0.795 dan IoU 0.7077 serta menghasilkan prediksi spasial tumor yang akurat terhadap *ground truth*. Model klasifikasi berbasis CNN ini terbukti mampu mengatasi kasus segmentasi citra dengan efektif dan akurat tetapi dalam jumlah data dan kebutuhan perangkat komputasi yang besar.

Dalam tahap ekstraksi fitur, salah satu pendekatan yang lebih sederhana tetapi tetap efektif adalah metode berbasis tekstur, seperti Local Binary Pattern (LBP). Pada kasus diagnosis tumor otak, penelitian oleh Kaplan dkk. (2020) mengimplementasikan konsep ekstraksi fitur LBP untuk mempercepat proses

diagnosis sekaligus meningkatkan peluang keselamatan pasien. Selain melakukan klasifikasi tumor otak pasien, fokus pada penelitian ini juga tertuju pada implementasi pendekatan teknik ekstraksi fitur yang merupakan pengembangan teknik LBP klasik, yaitu nLBP dan α LBP. Penelitian ini menggunakan data asli yang bersumber dari Nanfang Hospital dan Tianjin Medical University General Hospital di China sejak tahun 2005 hingga 2010. Dataset terdiri dari citra T1-weighted MRI berukuran 512×512 piksel dengan total 3.064 *slices* dari 233 pasien dan memiliki *ground truth* yang ditentukan secara manual oleh 3 orang ahli radiologi. Sama seperti LBP klasik, teknik nLBP mengekstraksi fitur piksel berdasarkan hubungan antara tetangga piksel yang mengelilinginya dalam 3×3 . Nilai setiap digit biner akan diperoleh berdasarkan perubahan nilai piksel tetangga dengan piksel tetangga berikutnya. Sebuah parameter d juga digunakan yang berfungsi untuk menentukan jarak piksel satu dengan piksel selanjutnya yang akan dibandingkan. Sementara itu, fitur dari teknik α LBP diperoleh berdasarkan hubungannya dengan piksel tetangga dalam sudut tertentu, bukan piksel tetangga yang mengelilinginya. Ketiga teknik ekstraksi fitur berbasis LBP tersebut menghasilkan sebuah histogram fitur yang mencerminkan pola yang dimiliki oleh suatu citra. Pola ini digunakan pada tahap klasifikasi, yaitu k-Nearest Neighbor (KNN), Artificial Neural Network (ANN), Random Forest (RF), Averaged One-Dependence Estimators (A1DE), Linear Discriminant Analysis (LDA), dan Support Vector Machine (SVM) dengan menggunakan teknik validasi *10-fold cross validation* dan metrik evaluasi *accuracy*, *precision*, dan *F-criteria*. Hasil terbaik yang diperoleh dari setiap kombinasi metode ekstraksi fitur dengan arsitektur klasifikasinya adalah nLBP dan KNN dengan akurasi tertinggi sebesar 95.56%. Kombinasi tersebut memiliki hasil yang lebih baik daripada α LBP dengan nilai $\alpha=45$ dan metode klasifikasi KNN di angka 90.57% serta LBP klasik dengan KNN di angka 93.28%. Penelitian ini menunjukkan bahwa model dengan metode ekstraksi fitur berbasis LBP memiliki beberapa kelebihan, seperti beban data dan komputasi yang rendah, sederhana, mudah diaplikasikan, serta *explainable* dengan tetap mempertahankan performa klasifikasi yang dapat diandalkan dalam rangka membantu proses diagnosis tenaga medis.

Metode ekstraksi fitur berbasis LBP yang efisien membutuhkan algoritma klasifikasi yang tepat untuk dapat menghasilkan performa yang optimal, salah satunya adalah SVM. Seperti pada penelitian yang telah dilakukan oleh Kaplan dkk. (2020), Yang dkk. (2021) juga membuktikan bahwa SVM mampu bekerja dengan baik dalam beban komputasi yang ringan dengan jumlah data yang terbatas, meskipun dengan hasil performa yang masih di bawah CNN. Dalam penelitian tersebut, dilakukan pengembangan model untuk kasus segmentasi citra MRI tumor otak berjenis *low-grade glioma* (LGG) pada dataset yang bersumber dari The Cancer Imaging Archive (TCIA) sejumlah 2.470 citra MRI FLAIR (Fluid-Attenuated Inversion Recovery). Segmentasi dilakukan dengan membandingkan dua metode SVM dan CNN. Pada algoritma SVM, setiap pasien memiliki modelnya masing-masing yang dilatih menggunakan data dari salah satu *slice* citra MRI beserta hasil segmentasi *ground truth* manualnya, sedangkan *slice* lainnya digunakan sebagai data validasi atau pengujian. Data citra yang digunakan telah melalui tahap *preprocessing* dengan *grayscale* dan ekstraksi fitur dengan 7 filter, yaitu Sobel, Gabor, Canny, Gaussian, Median, dan Variance sebelum masuk ke tahap segmentasi. Sementara itu, algoritma CNN menggunakan data citra MRI asli dan *mask* yang telah melalui tahap augmentasi dengan *horizontal flipping* serta rotasi dalam 90, 180, dan 270 derajat. Tahap tersebut menghasilkan total 19.760 citra yang dibagi ke 90% data untuk pelatihan dan 10% data untuk pengujian. Dari keseluruhan model yang terbentuk, SVM menghasilkan nilai rata-rata akurasi sebesar 93.7% dengan median 97.6% tetapi hanya 67 model dari total 109 model yang berhasil mencapai nilai *F1-score* lebih dari 0.5. Sementara itu, model CNN yang dibentuk berhasil memperoleh nilai akurasi sebesar 99.8% dan *F1-score* sebesar 99.9%. Pada kasus ini, metode CNN terbukti sangat akurat tetapi dengan keterbatasan yang cukup signifikan, seperti memerlukan data yang sangat banyak, waktu pelatihan yang lama, dan sumber daya komputasi dengan performa yang tinggi. Di sisi lain, metode SVM memiliki nilai akurasi yang lebih rendah dibandingkan dengan CNN serta perlu dibangun sebuah model yang berbeda untuk pasien yang berbeda. Meskipun demikian, metode SVM tetap memiliki beberapa keunggulan dibandingkan dengan metode CNN, seperti

kebutuhan data pelatihan yang lebih ringan, waktu pelatihan yang jauh lebih cepat, dan hampir tidak memerlukan perangkat dengan spesifikasi yang tinggi. Penelitian tersebut membuktikan bahwa metode SVM masih relevan untuk mengatasi permasalahan pada fasilitas kesehatan yang masih mengalami keterbatasan data, waktu, maupun infrastruktur komputasi.

Penelitian lain mengenai implementasi metode SVM untuk menangani permasalahan segmentasi sekaligus klasifikasi tumor otak juga telah dilakukan oleh Rao dan Karunakara (2022). Penelitian ini bertujuan untuk membantu proses diagnosis manual oleh radiolog yang memakan banyak waktu sekaligus tinggi akan potensi kesalahan dengan mengembangkan model segmentasi dan klasifikasi yang memiliki performa akurasi lebih baik daripada model-model terdahulu. Dataset yang diambil dari tiga sumber digunakan selama proses pengembangan model, yaitu BRATS 2018, 2019, dan 2020 dalam empat tipe citra MRI, yaitu T1, T2, T1C, dan Flair-Ground truth dari total 886 pasien. Pada tahap *pre-processing*, digunakan metode Normalized Median Filtering (NMF) sebagai *blur-removal* yang mampu menghaluskan (*smoothen*) dan menghapus *salt and pepper noise* citra yang impulsif sekaligus tetap mempertahankan nilai fitur tepi (*edge*) melalui penggantian nilai piksel dengan mediannya dalam radius 3×3 . Normalisasi juga digunakan dengan melakukan *resize* ke dalam ukuran 256×256 . *Binomial thresholding* digunakan sebagai metode segmentasi berdasarkan *threshold* dari nilai mean dan varians histogram probabilitas binomial citra. Tahap ekstraksi fitur tekstur citra menggunakan metode Gray-Level Co-occurrence Matrix (GLCM) yang menentukan hubungan spasial antara dua piksel, yaitu seberapa sering sepasang piksel dengan nilai intensitas tertentu muncul bersama pada jarak dan arah tertentu. Metode GLCM juga dikombinasikan dengan Spatial Grey Level Dependence Matrix (SGLDM) yang melakukan estimasi probabilitas kondisi pasangan dua piksel muncul pada jarak dan arah tertentu. SGLDM memperoleh fitur spasial arah atau jarak dari rata-rata empat arah yang diestimasi pada penelitian ini. Fitur tersebut akan diseleksi menggunakan metode Harris Hawks Optimization (HHO) untuk memilih fitur yang relevan dan membuang fitur yang redundan. HHO melakukan seleksi fitur dengan meniru perilaku *harris hawks bird*

dengan menggunakan taktik *surprise pounce* melalui fase eksplorasi dan eksploitasi. Fase eksplorasi dilakukan untuk mencari ruang solusi, sedangkan fase eksploitasi dilakukan untuk mencari solusi terbaik berdasarkan tingkat energi yang diperoleh dari fase transisi di antara kedua fase tersebut. Pencarian solusi pada fase eksploitasi menggunakan beberapa pola dengan tujuan untuk memperoleh hasil yang optimal secara global. Tahap klasifikasi menggunakan konsep dari metode SVM, yaitu Kernel Support Vector Machine (KSVM) yang memanfaatkan *kernel function* untuk memetakan data ke dimensi yang lebih tinggi menggunakan tiga jenis *kernel*, yaitu *sigmoid*, *linear*, dan RBF dengan optimasi *hyperparameter* menggunakan metode Social Ski Driver (SSD). Selain untuk optimasi, metode SSD juga digunakan untuk menggolongkan jenis tumor ganas (*malignant*) yang muncul menjadi tingkat rendah, sedang, dan tinggi. Berdasarkan tahapan pengembangan model tersebut, hasil performa model yang diperoleh berdasarkan metrik evaluasi *precision*, *recall*, *accuracy*, *F1-score*, dan *FNR* menunjukkan nilai akurasi tertinggi di angka 99.2%, 99.36%, dan 99.15% untuk masing-masing dataset yang digunakan, melebihi performa yang dihasilkan oleh model-model terdahulu. Hasil ini menunjukkan bahwa dengan kombinasi metode yang tepat, model berbasis SVM yang dalam kasus ini adalah KSVM-SSD dapat memperoleh tingkat akurasi performa deteksi, segmentasi, dan klasifikasi beserta optimasi fitur yang lebih baik dengan kompleksitas komputasi yang tetap efektif dan efisien.

Selain Kaplan (2020) dan Yang (2021), kombinasi metode ekstraksi fitur dan algoritma klasifikasi LBP dan SVM pernah digunakan oleh penelitian terdahulu untuk mengatasi permasalahan di lingkup yang sama, yaitu diagnosis penyakit tumor otak manusia. Penelitian tersebut dilakukan oleh Basthikodi dkk. (2024) yang mengembangkan model dengan mengimplementasikan metode LBP dan Histogram of Oriented Gradients (HOG) untuk ekstraksi fitur, Principal Component Analysis (PCA) untuk reduksi dimensi, serta SVM sebagai algoritma klasifikasi. Dengan menggunakan kombinasi dari tiga dataset yang berbeda dari Kaggle dengan jumlah 7.023 data citra MRI dalam beberapa bidang anatomi, sistem yang dikembangkan dapat mengklasifikasikannya menjadi empat kelas

seperti pada penelitian-penelitian sebelumnya, yaitu *glioma*, *meningioma*, *pituitary*, dan *no tumor*. Citra MRI berukuran 64×64 piksel yang telah melewati tahap *preprocessing* berupa *flattening*, augmentasi, normalisasi, dan histogram *equalization* akan masuk ke tahap ekstraksi fitur. Metode LBP mengekstraksi fitur tekstur lokal yang mampu mengatasi variasi pencahayaan citra dalam histogram, sedangkan metode HOG mengekstraksi fitur bentuk dan struktur global dalam vektor gradien. Fitur tersebut memiliki dimensi yang akan direduksi oleh PCA melalui transformasi linear untuk mengurangi overfitting dan meningkatkan efisiensi komputasional dengan tetap mempertahankan 95% variansi data. Berdasarkan metrik evaluasi *accuracy*, *precision*, *recall*, dan *F1-score*, klasifikasi yang dilakukan oleh algoritma SVM saja menghasilkan nilai akurasi di angka 86.57%. Nilai ini relatif bertambah saat SVM dikombinasikan dengan metode lain, yaitu kombinasi SVM dengan PCA menghasilkan nilai akurasi 94.2%, SVM dengan HOG dan LBP menghasilkan nilai akurasi 95.95%, serta hasil terbaik dari kombinasi SVM dengan HOG, LBP, dan PCA dengan nilai akurasi 96.03%. Kombinasi tersebut menghasilkan performa model dengan yang efisien dan mampu menangani jumlah data yang sedang serta sumber daya yang terbatas, bahkan mampu bersaing dengan model yang lebih kompleks dan berat secara komputasi.

Berdasarkan uraian penelitian-penelitian sebelumnya, dapat disimpulkan bahwa setiap metode dan algoritma memiliki kelebihan dan kekurangannya masing-masing dalam menganalisis citra MRI untuk mengatasi permasalahan diagnosis tumor otak. Penelitian ini berfokus pada optimalisasi kelebihan yang dimiliki oleh kombinasi metode LBP dan algoritma SVM yang diharapkan dapat menghasilkan sebuah model dengan performa yang baik serta tetap sederhana, ringan, dan *explainable* pada sumber daya terbatas. Penelitian ini juga berupaya untuk memberikan alternatif arsitektur dan algoritma diagnosis yang lebih ringan dibandingkan model-model berbasis *deep learning* dengan tetap mempertahankan performa yang kompetitif. Ringkasan dan perbandingan dari penelitian-penelitian relevan tersebut yang sekaligus menjadi acuan pada penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 Tinjauan Pustaka

No	Peneliti & Tahun	Dataset	Ekstraksi Fitur	Algoritma / Model	Hasil	Keterangan
1	Özkaraca dkk. (2023)	Sumber dari Kaggle (Kombinasi figshare, SARTAJ dataset, dan Br35H) dengan total 7.021 citra MRI.	Tidak dilakukan ekstraksi fitur. Klasifikasi langsung menggunakan CNN.	Basic CNN, VGG16 Net, DenseNet, dan Modified CNN.	Modified CNN dengan F1-score 97%., lebih tinggi daripada model lain (92%, 86%, 85%).	+ Performa akurasi dan F1-score tinggi dibanding model lain. - Model membutuhkan performa <i>resource</i> yang tinggi, waktu yang lama, arsitektur yang kompleks, dan data dalam jumlah besar.
2	Sinaga dkk. (2025)	Sumber dari Kaggle dengan total 20.672 citra MRI.	Tidak dilakukan ekstraksi fitur. Klasifikasi langsung menggunakan CNN.	CNN sederhana dan visualisasi hasil untuk Explainable AI (XAI).	Model CNN dengan akurasi 96%.	+ Performa akurasi, generalisasi, dan interpretabilitas model baik. + Implementasi visualisasi dengan konsep Explainable AI (XAI). - XAI belum dijelaskan secara lebih mendetail dengan metode tertentu. - Jumlah data yang digunakan besar dan waktu pelatihan model lama.

3	Dhamara dkk. (2025)	Sumber asli dari Rumah Sakit Islam Jakarta Cempaka Putih dengan total 3.064 citra MRI.	Tidak dilakukan ekstraksi fitur. Klasifikasi langsung menggunakan CNN (U-Net).	U-Net, arsitektur turunan CNN dengan basis <i>encoder-decoder</i> .	Metrik evaluasi <i>dice</i> sebesar 0.795 dan IoU 0.7077 pada <i>learning rate</i> $1e^{-4}$ dan 60 <i>epoch</i> .	+ Performa dan akurasi tinggi pada data klinis asli. - Kebutuhan data dan perangkat komputasi yang besar.
4	Kaplan dkk. (2020)	Sumber asli dari Nanfang Hospital dan Tianjin Medical University General Hospital (2005-2010) dengan total 3.064 <i>slices</i> citra T1-weighted MRI.	LBP klasik, nLBP, dan α LBP.	KNN, ANN, RF, AIDE, LDA, dan SVM dengan 10- <i>fold cross validation</i> .	Hasil akurasi terbaik dari setiap metode ekstraksi fitur: • αLBP + KNN: 90.57% • LBP + KNN: 93.28% • nLBP + KNN: 95.56%	+ Dataset asli dan terverifikasi oleh radiolog ahli. + Metode efektif dan efisien dengan performa yang kompetitif dengan <i>deep learning</i>. - Belum berfokus pada eksplorasi lebih lanjut algoritma SVM untuk klasifikasi.
5	Yang dkk. (2021)	Sumber dari TCIA dengan total 2.470 citra MRI FLAIR LGG. Augmentasi	Sobel, Gabor, Canny, Gaussian, Median, dan	Segmentasi SVM dan CNN	Model SVM dengan rata-rata akurasi 93.7% dengan median 97.6% dan model CNN	+ Kebutuhan data, waktu, dan perangkat SVM jauh lebih ringan daripada CNN. - Perlu dibangun model untuk

		menjadi total 19.760 data pada CNN.	Variance.		dengan akurasi 99.8% dengan F1- <i>score</i> 99.9%.	setiap pasien. - Performa akurasi lebih rendah daripada CNN.
6	Rao dan Karunakara (2022)	Kombinasi BRATS 2018, 2019, dan 2020 dalam empat tipe citra MRI (T1, T2, T1C, dan FLAIR) dari total 886 pasien.	GLCM dan SGLDM dengan seleksi fitur HHO.	KSVM <i>sigmoid</i> , <i>linear</i> , dan RBF dengan optimasi SSD.	Akurasi untuk setiap dataset sebesar 99.2%, 99.36%, dan 99.15%.	+ Performa deteksi, segmentasi, klasifikasi, dan optimasi baik dan efisien. - Metode yang digunakan kompleks dengan banyak tahapan.
7	Basthikodi dkk. (2024)	Kombinasi tiga dataset Kaggle dengan total 7.023 citra MRI dalam beberapa bidang anatomi.	LBP dan HOG dengan PCA untuk reduksi dimensi.	SVM	Akurasi klasifikasi kombinasi model: • SVM: 86.57% • SVM + PCA: 94.2% • SVM + HOG + LBP: 95.95% • SVM + HOG + LBP + PCA: 96.03%	+ Akurasi yang diperoleh cukup baik meskipun hanya menggunakan metode klasik dan data yang terbatas. - Belum diuji secara langsung dengan model yang lebih kompleks pada dataset yang sama.

BAB III

LANDASAN TEORI


3.1 Tumor Otak

Tumor otak adalah sebuah kasus medis di mana terjadi pertumbuhan sel secara tidak normal di suatu bagian otak atau sekitarnya. Abnormalitas perkembangan sel ini dapat terjadi di berbagai area otak, termasuk di lapisan pelindung otak, dasar tengkorak, batang otak, sinus dan rongga hidung, serta bagian lainnya (Johns Hopkins Medicine, n.d.). Berdasarkan sifatnya, tumor otak terbagi menjadi tumor ganas (*malignant*) dan tumor jinak (*benign*). Tumor ganas, atau yang biasa disebut kanker, menjadi kasus yang berbahaya karena mampu menyebar ke bagian tubuh lain. Sebaliknya, tumor jinak tidak menyebar ke bagian tubuh lain sehingga hampir tidak mengancam jiwa. Namun, dalam beberapa kasus, khususnya tumor otak, tumor jinak tersebut masih sangat memungkinkan untuk memberikan dampak yang serius, bahkan mematikan, apabila lokasi, ukuran, serta perkembangannya menekan bagian vital dan mengganggu fungsi otak (American Cancer Society, 2020). Berdasarkan sumber pertumbuhannya, tumor otak yang berasal dari perkembangan abnormal sel di bagian otak itu sendiri disebut tumor otak primer, sedangkan sel tumor yang berkembang dari bagian tubuh lain hingga menyebar ke area otak disebut tumor otak metastasis. Beberapa tipe tumor otak yang paling sering ditemukan adalah seperti glioma, meningioma, dan pituitary (Mayo Clinic, 2024).

3.2 Magnetic Resonance Imaging (MRI)

Berdasarkan penelitian oleh Azhar dan Chong (2022), prinsip kerja metode pencitraan Magnetic Resonance Imaging (MRI) utamanya adalah dengan memanfaatkan sifat *nuclear magnetic resonance* yang dimiliki oleh atom dengan jumlah proton atau neutron yang ganjil. Pada tubuh manusia, atom tersebut dapat ditemukan pada molekul air, lebih tepatnya senyawa H_2O yang tersebar di sebagian besar bagian tubuh manusia, seperti daging, darah, tulang, dan jaringan biologis lainnya. Dalam senyawa H_2O , atom hidrogen memiliki jumlah proton tunggal dan merupakan atom paling melimpah yang dapat ditemukan di jaringan biologis manusia.

Setiap proton memiliki momen magnetiknya masing-masing dengan orientasi yang acak. Komponen superkonduktor magnet MRI akan menciptakan medan magnet eksternal (B_0) yang kuat untuk mengubah orientasi magnetisasi dari proton tersebut menjadi sejajar sepanjang arah longitudinal dari B_0 . Ilustrasi perubahan orientasi akibat B_0 tersebut ditunjukkan pada Gambar 3.1. Kekuatan medan magnet yang dihasilkan berkisar antara 1.5 hingga 3 Tesla, atau sekitar 50.000 hingga 100.000 kali kekuatan medan magnet Bumi. Untuk memperoleh sinyal yang digunakan dalam tahap pencitraan, *radiofrequency* (RF) *pulse* dipancarkan untuk membelokkan vektor magnetisasi proton dari bidang longitudinal B_0 ke bidang transversalnya. Ketika RF berhenti dipancarkan, proton yang kembali ke orientasi awal atau relaksasi akan memancarkan sinyal elektromagnetik yang ditangkap oleh komponen RF *coils* dan akan diproses komputer untuk menghasilkan citra MRI.



Gambar 3.1 Orientasi Proton terhadap Medan Magnet Eksternal (Azhar & Chong, 2022)

Proses relaksasi berpengaruh kepada intensitas sinyal yang dipancarkan dan hasil citra yang diperoleh. Terdapat dua jenis relaksasi, yaitu relaksasi T1 yang menggambarkan seberapa lama waktu pemulihan magnetisasi longitudinal atom hingga ke 63% dari nilai awal serta relaksasi T2 yang menggambarkan seberapa lama waktu berkurangnya magnetisasi transversal atom hingga mencapai 37% dari nilai awal. Kedua nilai tersebut akan menentukan seberapa terang jaringan yang sedang diamati akan muncul di citra MRI yang dihasilkan.

Pencitraan non-invasif menggunakan MRI memiliki beberapa keunggulan apabila dibandingkan teknik populer lainnya. Berbeda dengan metode sinar-X (*X-ray*), MRI relatif lebih aman karena tidak menggunakan paparan radiasi ionisasi yang berpotensi menimbulkan efek biologis tertentu pada tubuh. Selain itu, dalam kasus pengamatan jaringan lunak atau organ, termasuk otak, MRI lebih unggul

daripada Computed Tomography (CT) dalam hal diferensiasi jaringan yang sehat dengan jaringan yang abnormal. Pada perkembangannya, MRI juga dapat dimanfaatkan untuk melakukan pencitraan aliran darah arteri melalui Magnetic Resonance Angiography (MRA). Selain itu, MRI juga dapat menentukan area aktivasi otak saat terjadi suatu fungsi kognitif maupun motorik, seperti saat mengingat atau berbicara melalui Functional Magnetic Resonance Imaging (fMRI) (Johns Hopkins Medicine, n.d.).

3.3 Pengolahan Citra Digital

Prinsip utama pengolahan citra digital didasari pada konversi sinyal gambar analog kontinu menjadi sinyal digital melalui *sampling* dan kuantisasi sehingga dapat diolah secara digital (Liu, 2024). Citra digital direpresentasikan sebagai matriks dua dimensi $M \times N$ dengan setiap elemennya merepresentasikan *pixel element* atau piksel dengan nilai intensitasnya masing-masing yang dapat berupa biner, skala abu-abu (*grayscale*), atau citra berwarna. Citra dapat melewati tahap transformasi atau kalkulasi secara matematis untuk melewati tahap pemrosesan yang biasanya meliputi akuisisi citra, *preprocessing*, segmentasi, ekstraksi fitur, klasifikasi, dan rekognisi. Berdasarkan buku yang ditulis oleh Gonzalez dan Woods (2018) berjudul “Digital Image Processing”, aspek penglihatan yang dimiliki komputer digital mampu menangani kasus-kasus visual yang tidak dapat diselesaikan oleh manusia secara langsung, seperti spektrum elektromagnetik mulai dari gelombang gamma hingga gelombang radio, maupun gelombang ultrasonik, mikroskop elektron, dan *computer-generated images* (CGI). Buku ini juga membagi proses pengolahan citra menjadi tiga paradigma, yaitu *low-level* di mana *input* dan *output*-nya berupa citra, *mid-level* dengan *output* berupa fitur atau objek hasil ekstraksi informasi citra, serta *higher-level* yang dapat menginterpretasikan citra layaknya pemahaman manusia.

3.3.1 Preprocessing

Melalui berbagai metode, pengolahan citra digital bertujuan untuk memperoleh informasi penting dari sebuah gambar (Archana & Jeevaraj, 2024). Tahap awal yang sering dilakukan adalah *preprocessing*, yaitu mempersiapkan citra mentah yang belum diolah agar dapat memperoleh hasil yang lebih jernih, akurat, dan dapat diandalkan untuk digunakan di tahap selanjutnya. Metode yang dilakukan pada tahap ini meliputi restorasi, yaitu mendapatkan kembali keutuhan dan kualitas

citra yang mungkin telah terdistorsi atau terdegradasi, maupun mendapatkan detail yang tersembunyi. Metode lainnya yang dapat dilakukan adalah *enhancement*, yaitu meningkatkan kualitas citra agar mendapatkan detail dan interpretabilitas yang lebih baik dengan memperoleh detail tersembunyi, meningkatkan kontras, dan mempertajam tepi objek.

3.3.2 Ekstraksi Fitur

Tahap ekstraksi fitur dibagi menjadi dua proses, yaitu *feature detection* dengan mencari fitur yang akan dianalisis, serta *feature description* yang memberikan nilai atribut kuantitatif ke fitur yang terdeteksi (Gonzalez & Woods, 2018). Pada kasus data citra, fitur yang diperoleh akan lebih ideal jika memiliki karakteristik independen atau invarian terhadap variasi lokasi, rotasi, ukuran, pencahayaan, maupun sudut pandang citra yang akan diekstraksi. Ciri tekstur dapat dimanfaatkan sebagai salah satu fitur yang memenuhi sebagian besar kriteria tersebut sekaligus mampu menjadi acuan pembeda antar objek dalam suatu citra. Salah satu metode yang dapat digunakan untuk melakukan teknik ekstraksi fitur adalah metode Local Binary Pattern (LBP) yang diperkenalkan oleh Ojala dkk. (2002). Mekanisme metode ini adalah dengan memperoleh representasi tekstur suatu bagian citra dalam lingkup lokal melalui proses komparasi intensitas dan *thresholding* antara suatu piksel dengan piksel lain yang mengelilinginya. Gray Level Co-occurrence Matrix (GLCM) yang dikembangkan oleh Haralick dkk. (1973) juga menjadi salah satu metode yang dapat digunakan untuk mengekstraksi fitur tekstur citra dengan mengacu kepada hubungan spasial suatu pasangan piksel. Mekanisme utama dari metode ini adalah menghitung jumlah kemunculan pasangan intensitas piksel dalam jarak dan sudut orientasi tertentu pada suatu citra. GLCM menghasilkan sebuah matriks ternormalisasi berisi hubungan spasial dari setiap piksel citra yang digunakan sebagai acuan perhitungan fitur-fitur statistik dengan fungsi dan karakteristiknya masing-masing. Fitur-fitur tersebut adalah seperti Energy untuk menghitung tingkat keseragaman tekstur, Contrast untuk menghitung variasi intensitas lokal, Entropy untuk mengukur tingkat ketidakaturan atau kompleksitas tekstur, Homogeneity untuk mengukur tingkat keseragaman tekstur, dan lain sebagainya. Ciri tekstur yang diperoleh dari fitur-fitur ini yang mampu merepresentasikan informasi penting citra dan menjadi *input* bagi algoritma selanjutnya. Selain itu, Dalal dan Triggs (2005) mengembangkan teknik Histogram of Oriented Gradients (HOG) yang berfokus

kepada pola orientasi gradien untuk memperoleh bentuk dan tekstur lokal citra. Setiap piksel citra melewati proses penghitungan gradien, yaitu arah dan perubahan intensitas terhadap piksel lain. Citra dibagi menjadi banyak area sel kecil untuk membentuk histogram orientasi berdasarkan anggota piksel dengan bobot besar gradiennya. Beberapa gabungan sel dikelompokkan secara tumpang tindih menjadi blok yang lebih besar untuk dinormalisasi sebelum digunakan sebagai vektor representasi tekstur citra. Fitur yang diperoleh pada tahap ini sangat dipengaruhi oleh kualitas citra yang dihasilkan dari tahap *preprocessing*. Representasi fitur tersebut berupa vektor dengan dimensi tertentu yang akan dimanfaatkan sebagai sumber informasi pada tahap yang lebih kompleks (Archana & Jeevaraj, 2024). Fitur yang diperoleh dari tahap ini terkadang memiliki dimensi yang sangat besar sehingga untuk mengoptimalkan efisiensi, diperlukan proses tambahan untuk mereduksi dimensi tersebut, seperti Principle Component Analysis (PCA).

3.3.3 Klasifikasi

Gonzalez dan Woods (2018) menjelaskan bahwa tujuan utama tahap klasifikasi adalah untuk menentukan label kelas berdasarkan pola yang dimiliki oleh suatu fitur. Data yang direpresentasikan oleh fitur tersebut akan dikelompokkan ke dalam suatu kelas yang bersifat unik dengan anggota yang memiliki kesamaan karakteristik. Berdasarkan penelitian yang dilakukan oleh Chen dkk. (2024), metode *machine learning* tradisional yang digunakan untuk tugas klasifikasi membutuhkan proses ekstraksi fitur yang dilakukan secara manual, misalnya untuk memperoleh representasi warna, tekstur, dan bentuk pada suatu data citra. Performa klasifikasi yang dihasilkan juga sangat bergantung kepada kualitas dari fitur-fitur tersebut. Algoritma yang sering digunakan adalah seperti k-Nearest Neighbor, Decision Tree, Random Forest, Naive Bayes, Support Vector Machine, dan berbagai metode lain dengan kekurangan dan keunggulannya masing-masing. Di sisi lain, metode berbasis *deep learning* menerapkan teknik ekstraksi yang dapat dilakukan secara otomatis, sehingga mampu mengatasi permasalahan kebutuhan waktu dan tenaga yang besar untuk memperoleh fitur dari suatu data melalui *feature engineering*. Pada kasus *computer vision* dan pengolahan citra, salah satu algoritma *deep learning* yang paling populer adalah Convolutional Neural Network.

3.3.3.1 Klasifikasi Berbasis *Machine Learning*

Russell dan Norvig (2021) menjelaskan beberapa metode klasifikasi populer menggunakan algoritma *machine learning* untuk menyelesaikan berbagai tugas, seperti klasifikasi dan regresi. Klasifikasi menggunakan algoritma k-Nearest Neighbor (KNN) bekerja dengan mengklasifikasikan data dari mayoritas kelas k tetangga terdekat berdasarkan metrik jarak tertentu, seperti Euclidean, Manhattan, atau Hamming *distance*. Algoritma Decision Tree (DT) melakukan klasifikasi dengan mengolah setiap fitur data melalui suatu rangkaian keputusan dengan struktur yang berbentuk seperti pohon (*tree*). Pengambilan keputusan berdasarkan setiap atribut data dilakukan dari akar *root node* menuju masing-masing *branch* dengan alur sesuai dengan nilai hasil pengujian atribut di *internal node* hingga memperoleh hasil klasifikasi kelas data di *leaf node*. Dengan menggabungkan banyak DT, algoritma Random Forest (RF) memanfaatkan setiap *tree* dengan data dan atribut yang berbeda secara acak (*random*) satu sama lain. RF merupakan salah satu algoritma *ensemble learning* yang mengkombinasikan beberapa model dengan teknik *bagging*, yaitu melakukan pelatihan dan perbandingan model secara independen dan paralel. Dalam kasus klasifikasi suatu data, prediksi RF diperoleh berdasarkan mayoritas *vote* dari keseluruhan *tree*. Metode klasifikasi dengan algoritma Naive Bayes (NB) mengasumsikan secara *naive* bahwa atribut data adalah independen atau tidak terikat antara satu dengan yang lainnya. Dengan menerapkan teorema Bayes, prediksi kelas dari suatu data dipilih berdasarkan nilai probabilitas tertinggi di antara semua kelas.

3.3.3.2 Klasifikasi Berbasis *Deep Learning*

Salah satu algoritma yang paling sering digunakan, khususnya pada kasus pengolahan citra digital adalah Convolutional Neural Network (CNN). Menurut Goodfellow (2016), CNN dikhususkan untuk mengolah data dengan struktur matriks seperti *grid*, misalnya data citra yang direpresentasikan oleh matriks piksel dua dimensi. Algoritma ini merupakan salah satu jenis jaringan saraf tiruan (*artificial neural network*) yang mengutamakan penggunaan teknik konvolusi untuk mengekstraksi fitur secara otomatis. Berdasarkan penjelasan oleh Albawi dkk. (2017), arsitektur CNN terdiri atas beberapa *layer* yang saling terhubung secara sekuensial untuk mengolah suatu data. Rangkaian proses komputasi tersebut diawali oleh *convolutional layer* yang melakukan deteksi dan ekstraksi fitur citra menggunakan *filter* dengan ukuran dan karakteristik tertentu. Hasil ekstraksi yang

diperoleh akan melewati *non-linearity layer* untuk diolah menggunakan fungsi aktivasi non-linear, seperti *sigmoid*, *tanh*, dan ReLU yang memungkinkan sebuah model CNN mampu mempelajari pola atau fungsi non-linear yang lebih kompleks. Proses yang terjadi di *pooling layer* adalah reduksi dimensi atau resolusi dengan *down-sampling* untuk mengurangi kompleksitas sekaligus mempertahankan karakteristik fitur dengan metode tertentu, seperti *max-pooling*. Pada bagian akhir, *fully-connected layer* akan melakukan klasifikasi data berdasarkan gabungan fitur yang telah diperoleh dari seluruh *layer* sebelumnya. Setiap *node* yang ada di dalam jaringan ini terhubung dengan setiap *node* di *layer* berikutnya dengan *weight* dan *bias* yang telah dipelajari selama tahap pelatihan model.

3.4 Artificial Intelligence (AI)

Dalam bukunya yang berjudul “Artificial Intelligence: A Modern Approach”, Russell dan Norvig (2021) mendefinisikan kecerdasan buatan atau *artificial intelligence* (AI) adalah bidang ilmu komputer yang berfokus pada pengembangan suatu entitas cerdas yang mampu berpikir, bertindak, dan berperilaku secara logis atau rasional untuk mencapai suatu tujuan. Pendekatan yang digunakan untuk mendefinisikan AI dalam konsep tersebut adalah *thinking humanly*, *thinking rationally*, *acting humanly*, dan *acting rationally*. Untuk mencapai tujuan tersebut, suatu sistem AI membutuhkan beberapa komponen atau kemampuan, yaitu *natural language processing* untuk berkomunikasi dengan baik melalui bahasa, *knowledge representation* untuk merepresentasi pengetahuan, *automated reasoning* untuk menjawab pertanyaan dan mengambil kesimpulan, *machine learning* untuk beradaptasi dengan kondisi baru dan mendeteksi suatu pola, *computer vision* dan *speech recognition* untuk memahami lingkungan, serta *robotics* untuk bergerak dan memanipulasi objek. Salah satu metode untuk mengevaluasi kecerdasan suatu entitas dengan kemampuan yang dimilikinya adalah melalui eksperimen Turing Test yang diciptakan oleh Alan Turing di tahun 1950 untuk menguji apakah respons komputer dengan respons manusia dapat dibedakan oleh seorang penguji. Lingkup implementasi AI tergolong universal, mulai dari fungsi umum, seperti pembelajaran, penalaran, dan persepsi, hingga tugas-tugas spesifik, seperti bermain catur, membuktikan teorema matematika, mengemudi mobil, hingga diagnosis penyakit.

3.5 *Machine Learning*

Salah satu komponen AI yang populer dan menjadi topik-topik yang banyak diangkat pada penelitian terdahulu adalah *machine learning*, yang menurut Alpaydin (2010) adalah sebuah proses pemrograman komputer untuk mengoptimalkan performa melalui pembelajaran data atau pengalaman masa lalu dengan kriteria tertentu. Dalam prosesnya, *machine learning* bekerja dengan memanfaatkan data yang diperoleh dari *input* untuk melakukan proses pembelajaran dan pengenalan pola sehingga dapat merumuskan suatu *output* prediksi maupun deskripsi terkait dengan informasi yang telah dipelajari sebelumnya. Proses tersebut bertujuan untuk membentuk sebuah algoritma atau model dengan performa terbaik dan efisien melalui pencarian nilai parameter-parameter matematis yang paling optimal dalam menganalisis data selama tahap pembelajaran.


Sebagai salah satu bagian dari AI, proses pembelajaran pada algoritma *machine learning* secara umum dikategorikan menjadi tiga pendekatan untuk mencapai tujuannya, yaitu *supervised*, *unsupervised*, dan *reinforcement learning* (Alpaydin, 2010). Pendekatan *supervised learning* melakukan tugas pembelajaran sistem terhadap data *input* dengan label yang diberikan berdasarkan deskripsi atau fiturnya untuk dikategorikan ke kelas-kelas tertentu. Tujuan dari pendekatan ini adalah untuk memprediksi kelas yang akan dimiliki oleh data baru berdasarkan kesamaan ciri yang dimilikinya dengan kelas-kelas data yang telah dipelajari sebelumnya. Berbeda dengan *supervised learning* yang membutuhkan proses pelabelan, pendekatan *unsupervised learning* mempelajari dan menemukan pola tersembunyi berdasarkan deskripsi atau fitur dari kumpulan data yang tidak berlabel. Salah satu metode yang dapat digunakan adalah *clustering* yang bertujuan untuk mengelompokkan data berdasarkan kemiripan pola yang dimilikinya. Hasil pengelompokan yang diperoleh dari pendekatan ini perlu melewati proses analisis lebih lanjut untuk menemukan makna representasi dari setiap klaster yang terbentuk. Sementara itu, pendekatan *reinforcement learning* tidak hanya berfokus ke hasil yang diperoleh model, tetapi juga berfokus kepada rangkaian proses yang dilalui untuk mencapai hasil yang paling optimal. Dalam proses tersebut, setiap keputusan atau tindakan sistem yang berpengaruh terhadap rangkaian aksi yang diambil akan mendapatkan *reward* apabila benar dan *punishment* apabila salah berdasarkan aturan-aturan yang telah ditentukan. Pendekatan ini akan memaksimalkan *reward*

dan meminimalkan *punishment* yang diperoleh agar dapat mempelajari kebijakan (*policy*) terbaik yang harus diambil oleh suatu sistem.

3.6 Local Binary Pattern (LBP)

Ojala dkk. (2002) mengembangkan sebuah teknik ekstraksi fitur citra yang sederhana dan efisien secara teori maupun komputasional, yaitu Local Binary Pattern (LBP) yang digunakan untuk mendapatkan representasi tekstur dari suatu citra. LBP dikembangkan berdasarkan pola yang seragam dalam suatu area lokal citra dengan prinsip utamanya adalah melalui perbandingan intensitas setiap piksel dengan tetangganya dalam radius tertentu. Hasil dari setiap perbandingan tersebut menghasilkan sebuah bilangan biner yang dikonversikan menjadi bilangan desimal sebagai representasi fitur tekstur dari setiap piksel. Metode LBP akan menghasilkan histogram yang terbentuk dari distribusi nilai fitur tersebut sekaligus menjadi vektor representasi dari fitur tekstur yang dimiliki citra. Formula dasar yang digunakan dalam perhitungan LBP adalah seperti pada persamaan 3.1. Visualisasi skema penentuan jumlah piksel tetangga dan nilai radius yang digunakan ditunjukkan pada Gambar 3.2.

$$LBP_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p \quad (3.1)$$



Gambar 3.2 Visualisasi Skema Penentuan Variabel LBP (Ojala dkk., 2002)

Setiap intensitas piksel pusat g_c dibandingkan dengan setiap piksel tetangga g_p sebanyak P tetangga pada radius R . Fungsi *threshold* $s(x)$ yang didefinisikan pada persamaan 3.2 menentukan syarat digit biner yang akan mengembalikan nilai 1

apabila $x \geq 0$ dan 0 apabila $x < 0$. Dengan demikian, apabila intensitas piksel tetangga lebih besar atau sama dengan piksel pusat, maka digit biner yang diperoleh adalah 1, dan sebaliknya, jika intensitas piksel tetangga lebih kecil daripada piksel pusat, maka diperoleh nilai 0.

$$s(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0. \end{cases} \quad (3.2)$$

Ahonen dkk. (2004) juga menjelaskan bahwa metode penentuan jumlah tetangga (P) dan jaraknya dengan piksel pusat (R) tersebut merupakan salah satu perpanjangan operator dari konsep LBP dasar. Apabila terdapat titik yang tidak berada tepat di posisi piksel setelah ditentukan nilai P dan R , maka metode *circular* ini akan melakukan proses interpolasi bilinear. Selain metode tersebut, *uniform patterns* juga dapat digunakan dengan menyederhanakan fitur yang dihasilkan dari perhitungan sebelumnya. Fitur dikelompokkan berdasarkan jumlah transisi 0 ke 1 atau 1 ke 0 yang ada pada pola biner yang dihasilkan dengan ketentuan jika transisi tersebut berjumlah kurang dari tiga, maka termasuk ke dalam pola yang *uniform*. Pola-pola tersebut berfungsi untuk merepresentasikan kemunculan fitur mikro citra, seperti sudut, tepi, titik, maupun area datar. Pengelompokan ini membuat proses perhitungan metode LBP lebih sederhana dan efektif karena mampu menghasilkan histogram dan dimensi fitur yang lebih representatif.


LBP mampu melakukan ekstraksi fitur tekstur lokal dari suatu citra dengan beberapa kelebihan, seperti mampu menangani perubahan (invarian) terhadap variasi rotasi dan skala abu-abu, waktu komputasi yang cepat, kemampuan generalisasi yang baik, serta implementasi yang *straightforward* (Ojala dkk., 2002). Implementasi dari teknik ini sudah banyak digunakan di berbagai penelitian, khususnya tentang pengolahan citra, salah satunya dilakukan oleh Basthikodi dkk. (2024) yang mengolah data citra medis. Penelitian ini memanfaatkan data citra MRI otak manusia untuk dilakukan diagnosis penyakit tumor otak. Metode LBP digunakan sebagai metode ekstraksi fitur karena kesederhanaan kalkulasi dan kemudahan ekstraksi.

Berdasarkan penelitian yang dilakukan oleh Kaplan dkk. (2020), diajukan metode ekstraksi fitur yang merupakan turunan dari LBP klasik dengan memanfaatkan hubungan antar tetangga piksel, yaitu nLBP berbasis hubungan jarak dan α LBP berbasis hubungan sudut. Selain itu, Liao dkk. (2007) juga mengajukan metode Multi-scale Block LBP (MB-LBP), yaitu varian LBP yang menggunakan

ukuran tetangga yang lebih besar dengan memanfaatkan gabungan dari lebih dari satu piksel (*sub-region*) sebagai representasi piksel pusat dan tetangganya dalam berbagai ukuran. Setiap teknik yang digunakan akan menghasilkan sebuah pola biner yang akan dikonversi ke bilangan desimal dan dibentuk sebuah histogram dari setiap citra sebagai hasil proses ekstraksi fitur tekstur.

3.6.1 nLBP

Kaplan dkk. (2020) mengembangkan teknik nLBP dengan memanfaatkan 8 piksel tetangga yang ada di sekeliling piksel pusat untuk memperoleh representasi fitur tekstur lokal. Nilai tersebut diperoleh dengan membandingkan piksel antar tetangga, yaitu satu piksel dengan piksel berikutnya yang berurutan dalam rangkaian siklus. Setiap nilai digit pada representasi biner diperoleh dengan mekanisme perbandingan tersebut. Sebuah parameter d juga digunakan untuk menentukan jarak antar kedua tetangga yang akan dibandingkan sehingga teknik ini juga dapat disebut nLBP _{d} . Gambar 3.3 menunjukkan visualisasi proses perbandingan setiap piksel pada teknik nLBP dengan nilai parameter jarak d adalah 1 (B), 2 (C), dan 3 (D).



Gambar 3.3 Perbandingan Piksel pada Teknik nLBP (Kaplan dkk., 2020)


Dalam suatu jarak d tertentu, nilai intensitas sebuah piksel tetangga ke- i (P_i) yang lebih besar daripada piksel tetangga berikutnya (P_j) akan menghasilkan nilai 1 pada digit biner representasi fitur, dan sebaliknya, nilai intensitas piksel ke- i yang lebih kecil daripada piksel ke- j berikutnya akan menghasilkan nilai 0. Fungsi *threshold* dari perhitungan tersebut dapat didefinisikan pada persamaan 3.3.

$$S(P_i > P_j) = \begin{cases} 1 & \text{if } P_i > P_j, \\ 0 & \text{if } P_i \leq P_j \end{cases} \quad (3.3)$$

3.6.2 α LBP

Sebagai salah satu varian dari teknik LBP klasik, Kaplan dkk. (2020) juga mengembangkan α LBP yang juga menerapkan teknik ekstraksi fitur tekstur lokal setiap piksel dengan memanfaatkan tetangga piksel pusat. Namun, berbeda dengan

teknik LBP klasik dan nLBP yang memanfaatkan piksel tetangga di sekeliling piksel pusat dalam sebuah siklus yang memutar, α LBP menggunakan parameter sudut α untuk menentukan arah atau orientasi piksel-piksel tetangga yang akan digunakan dalam proses ekstraksi fitur. Seperti pada visualisasi yang ditunjukkan oleh Gambar 3.4, parameter α digunakan untuk menentukan garis yang melewati piksel pusat dengan sudut α untuk menentukan 8 tetangga piksel yang dilewati garis dan akan menyusun digit biner representasi fitur.



Gambar 3.4 Penentuan Piksel pada Teknik α LBP (Kaplan dkk., 2020)

Proses ekstraksi fitur yang dilakukan adalah dengan membandingkan setiap intensitas piksel tetangga (P_i) terhadap piksel pusat (P_c) dalam sudut α tertentu. Hasil yang diperoleh untuk menentukan nilai digit representasi biner dirumuskan pada persamaan 3.4.

$$\alpha LBP_{\alpha} = \sum_{i=0}^P u(P_i - P_c) 2^i \quad (3.4)$$

3.6.3 Multi-scale Block LBP (MB-LBP)

Teknik LBP konvensional melakukan ekstraksi fitur citra secara lokal dengan ukuran ketetanggaan yang terbatas pada komparasi piksel tunggal. Untuk mengatasi keterbatasan tersebut, Liao dkk. (2007) mengembangkan metode MB-LBP sebagai varian dari LBP klasik dengan memperluas hubungan dan elemen ketetanggaan piksel pusat dari nilai tunggal menjadi rata-rata intensitas *sub-region*, yaitu gabungan beberapa piksel dalam suatu area. Ukuran piksel dari setiap *sub-region* atau blok tersebut beragam, seperti 3×3 , 9×9 , 15×15 , dan seterusnya sehingga mampu

menangkap struktur citra dalam lingkup mikro atau lokal sekaligus makro atau global. Teknik yang dilakukan adalah dengan melakukan perhitungan nilai rata-rata intensitas piksel dalam setiap elemen blok secara efisien menggunakan *integral image* sehingga menyebabkan teknik ini *robust* terhadap *noise*. Berdasarkan nilai representasi setiap blok tersebut, MB-LBP menerapkan teknik *thresholding* dalam 1 blok pusat dan 8 blok tetangga dengan mekanisme perbandingan nilai rata-rata intensitas seperti pada LBP klasik. Proses ini menghasilkan digit biner yang akan dikonversikan menjadi bilangan desimal sebagai data penyusun histogram fitur tekstur citra. Gambar 3.5 menunjukkan skema operasi MB-LBP dalam menentukan piksel yang masuk ke dalam blok dengan ukuran 9×9 .

	1		2		3			
	8		0		4			
	7		6		5			

Gambar 3.5 Visualisasi Blok MB-LBP (Liao dkk., 2007)


Pendekatan *uniform patterns* pada teknik LBP klasik tidak berlaku pada MB-LBP karena penggunaan blok melalui gabungan piksel yang lebih luas cenderung menghilangkan pola-pola yang berlaku pada atribut *uniform* LBP klasik. Oleh karena itu, Liao dkk. (2007) mengajukan konsep Statistically Effective MB-LBP (SEMB-LBP) untuk memperoleh representasi pola *uniform* berdasarkan analisis statistik. Metode ini menggunakan acuan distribusi kemunculan nilai representasi blok berdasarkan urutan persentase kemunculan nilai fitur lokal dari suatu histogram citra. Fitur yang memiliki jumlah kemunculan di bawah N akan diberi label tunggal sebagai *input* model klasifikasi. *Trade-off* yang terjadi terhadap jumlah histogram yang dipilih berhubungan dengan jumlah dimensi fitur dan variasinya sehingga diperlukan proses pemilihan jumlah *uniform patterns* yang mampu mengoptimalkan kedua faktor tersebut.

3.7 Support Vector Machine (SVM)

Konsep awal Support Vector Machine (SVM) diperkenalkan oleh Cortes dan Vapnik pada tahun 1995 dengan penelitian yang berjudul “Support-Vector Networks”. Mekanisme klasifikasi dua kelas (biner) ` SVM pada didasari pada tiga

ide, yaitu mencari *hyperplane* optimal dan memungkinkan perluasan vektor, konvolusi dari *dot-product* yang memperluas permukaan linear ke non-linear menggunakan fungsi *kernel*, serta *soft margin* yang memungkinkan adanya toleransi terhadap misklasifikasi selama proses pelatihan model. Klasifikasi dilakukan dengan membagi data ke dua kelas yang berbeda berdasarkan *hyperplane* dengan *margin*, yaitu jarak dari *hyperplane* ke masing-masing data terdekat (*support vector*) dari setiap kelas yang maksimal. Vapnik dan Chervonenkis (1974) memperkenalkan pendekatan tersebut yang memiliki asumsi bahwa semua data dapat dipisahkan secara linear dan tanpa ada misklasifikasi, atau yang disebut dengan SVM *hard margin*. Cortes dan Vapnik (1995) mengembangkan pendekatan SVM *soft margin*, di mana dimungkinkan adanya misklasifikasi untuk memperoleh klasifikasi yang optimal dengan mencari hasil *hyperplane* terbaik yang dibentuk dari *margin* yang maksimal dengan misklasifikasi atau error yang minimal (Maggioni & Spinelli, 2024).

Contoh skema klasifikasi SVM untuk memisahkan dua kelas ditunjukkan pada Gambar 3.3. Pada skema tersebut, *hyperplane* optimal digambarkan dengan garis putus-putus yang berada tepat di antara jarak terjauh dari kedua *margin*. Data dengan persegi berwarna abu-abu adalah *support vector*, yaitu data terdekat dari *hyperplane* sebagai titik penentuan *margin* antara kelas pertama -1 yang diilustrasikan dengan bentuk ○ dan kelas kedua +1 dengan bentuk ×.



Gambar 3.3 Contoh Skema Klasifikasi SVM (Cortes & Vapnik, 1995)

Secara matematis, formula untuk mendapatkan *hyperplane* optimal yang memisahkan dua kelas didefinisikan pada persamaan 3.3.

$$f(x) = w^T x + b = 0 \quad (3.3)$$

Di mana w adalah vektor bobot, x adalah vektor fitur, dan b adalah konstanta bias skalar. Perhitungan yang digunakan untuk menentukan kelas dari suatu nilai fitur didefinisikan pada persamaan 3.4.

$$y = \text{sign}(w^T x + b) \quad (3.4)$$

Berdasarkan aturan tersebut, maka apabila nilai data menghasilkan angka negatif, data tersebut masuk ke dalam kelas -1, begitu pula sebaliknya, data yang menghasilkan angka positif akan masuk ke dalam kelas +1. Sebuah *hyperplane* pada SVM *hard margin* dikatakan mampu memisahkan data secara linear tanpa error jika memenuhi batasan atau *constraint* yang ada pada persamaan 3.5.

$$y_i(w^T x_i + b) \geq 1, \forall i \quad (3.5)$$

Di mana $y_i \in \{-1, +1\}$ sehingga setiap data dari masing-masing kelas berada di luar *margin*. Di sisi lain, SVM *soft margin* memungkinkan adanya error atau noise yang ditunjukkan dengan tingkat *error* suatu data dengan variabel *slack* ξ_i . *Constraint* yang harus dipenuhi oleh setiap data didefinisikan pada persamaan 3.6.

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \xi_i \geq 0 \quad (3.6)$$

Semakin besar nilai yang diperoleh, semakin besar juga error yang dimiliki data tersebut (Jun, 2021). Oleh karena itu, berdasarkan ketentuan tersebut, dapat diperoleh bahwa untuk membentuk sebuah *hyperplane* yang sekaligus menjadi permasalahan utama optimasi algoritma SVM didefinisikan pada persamaan 3.7.

$$\min_{w,b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (3.7)$$

Parameter C juga ditambahkan untuk melakukan kalkulasi dan regulasi tingkat error data yang diperbolehkan. Tujuan utama dari penyelesaian persamaan tersebut adalah menyeimbangkan antara *margin* maksimal di bagian pertama persamaan ($\frac{1}{2} \|w\|^2$) dengan misklasifikasi minimal di bagian kedua ($C \sum_{i=1}^n \xi_i$) untuk memperoleh *hyperplane* yang paling optimal dengan akurasi terbaik (Maggioni & Spinelli, 2024).

Contoh yang ditunjukkan pada Gambar 3.2 memiliki persebaran data yang dapat dibagi oleh *hyperplane* secara linear. Namun, terdapat beberapa kasus di mana *hyperplane* tidak mampu memisahkan kedua kelas secara linear. Pada kasus ini,

diperlukan sebuah teknik untuk memetakan data ke dimensi yang lebih tinggi agar *hyperplane* tetap bisa mengklasifikasikan kedua kelas data secara linear dengan hasil yang kompetitif. Tanpa dilakukannya teknik pemetaan tersebut, klasifikasi non-linear akan meningkatkan beban komputasional secara signifikan. Teknik tersebut dilakukan dengan menggunakan fungsi *kernel* yang merupakan inti dari banyak algoritma *machine learning*, termasuk SVM (Badillo dkk., 2020). Fungsi *kernel* tersebut didefinisikan pada persamaan 3.8.


$$K(x_i, x_j) := \langle \phi(x_i), \phi(x_j) \rangle \quad (3.8)$$

Dari keseluruhan *kernel* yang ada, beberapa *kernel* yang paling sering digunakan beserta persamaannya dituliskan pada Tabel 3.1.

Tabel 3.1 Contoh Fungsi *Kernel* (Azzeh dkk., 2022)

Nama Kernel	Persamaan Kernel
Linear	$k(x, y) = x^T y + c$
Polinomial	$k(x, y) = (x + y)^d$
Radial Basis Function (RBF)	$k(x, y) = e^{(-\gamma \ x-y\ ^2)}$
Sigmoid	$k(x, y) = \tanh(ax^T y + c)$

Gambar 3.4 menunjukkan contoh sebaran data sebelum (kiri) dan sesudah (kanan) implementasi fungsi *kernel*. Saat berada di ruang dua dimensi, data yang tersebar dalam bentuk lingkaran ganda sulit bahkan tidak mungkin untuk dipisahkan secara linear. Namun, setelah fungsi *kernel* digunakan untuk memetakan data tersebut ke ruang tiga dimensi, secara visual, data tersebut dapat dipisahkan oleh sebuah *hyperplane* secara linear.



Gambar 3.4 Transformasi Dimensi Data dengan Kernel Function (Hafshejani & Moabarfard, 2022)

Secara konsep, mekanisme klasifikasi yang dilakukan oleh algoritma SVM adalah klasifikasi biner, yaitu terbatas kepada pembagian kelas data menjadi dua kelas yang berbeda. Oleh karena itu, untuk dapat melakukan klasifikasi data secara *multiclass*, diperlukan adanya perluasan metode dari algoritma SVM untuk mengatasi permasalahan tersebut. Seperti yang telah dijelaskan oleh Bishop (2006), metode atau pendekatan yang dapat digunakan adalah yaitu *one-versus-the-rest* dan *one-versus-one*. Pada pendekatan *one-versus-the-rest*, pelatihan dilakukan dengan menggunakan data dari salah satu kelas berlabel positif dengan data gabungan dari kelas lain yang diberi label negatif. Proses tersebut dilakukan oleh setiap n kelas data yang menghasilkan *hyperplane* sejumlah n . Pendekatan *one-versus-one* melakukan pelatihan untuk setiap pasangan kelas data. Setiap proses pelatihan akan dilakukan dengan menggunakan data dari pasangan dua kelas dan akan mengabaikan kelas lain. Hasilnya, pendekatan ini menghasilkan sejumlah $\frac{n(n-1)}{2}$ *hyperplane* yang akan terbentuk untuk sebanyak n kelas. Kedua pendekatan tersebut merupakan metode yang telah banyak digunakan untuk mengatasi permasalahan klasifikasi *multiclass* dengan menggunakan algoritma SVM.

3.8 Evaluasi Model

Tahap analisis dan penentuan seberapa baik performa generalisasi model dalam melakukan klasifikasi data dilakukan pada tahap evaluasi. Dengan mengacu kepada bagaimana model memprediksi label atau kelas dari data pengujian, tahap ini melakukan kalkulasi kinerja model berdasarkan metrik evaluasi tertentu hingga mencapai performa yang diharapkan. Salah satu tolok ukur kualitas klasifikasi model dapat diperoleh dengan menggunakan metode *confusion matrix*.

Menurut Yang dkk. (2021), *confusion matrix* adalah sebuah tabel berukuran 2×2 yang memvisualisasikan performa model *machine learning* dalam melakukan prediksi kelas data. Ukuran tabel tersebut dapat meningkat seiring dengan jumlah kelas yang digunakan, yaitu $n \times n$. Metode ini menganalisis performa model dengan menghitung berapa banyak data yang berhasil dan gagal diprediksi pada tiap kelas. Representasi performa model dalam bentuk tabel tersebut menghitung jumlah hasil klasifikasi model dalam empat indikator berbeda, yaitu *true negative* (TN) yang

menghitung data di kelas negatif yang berhasil diprediksi, *true positive* (TP) yang menghitung data di kelas positif yang berhasil diprediksi, serta *false negative* (FN) yang menghitung data di kelas positif yang gagal diprediksi, dan *false positive* (FP) yang menghitung data di kelas negatif yang gagal diprediksi. Nilai yang diperoleh dari setiap *cell* tersebut dapat digunakan untuk proses evaluasi selanjutnya menggunakan metrik lainnya. Contoh visualisasi hasil tabel *confusion matrix* yang diperoleh suatu model ditunjukkan pada Tabel 3.2.

Tabel 3.2 Contoh Hasil Evaluasi *Confusion Matrix* (Yang dkk., 2021)

Predictions	Condition positive (glioma) (pixels)	Condition negative (normal) (pixels)
Predicted positive (glioma) (pixels)	True positive =12,035	False positive (type I error) =5,443
Predicted negative (normal) (pixels)	False negative (type II error) =844	True negative =374,894

Selain *confusion matrix*, tahap evaluasi, khususnya untuk model klasifikasi juga dapat memanfaatkan beberapa metrik evaluasi lainnya dengan metode perhitungannya masing-masing (Archana & Jeevaraj, 2024). Metrik *accuracy* digunakan untuk menghitung rasio prediksi yang benar terhadap keseluruhan prediksi dengan menggunakan persamaan 3.9. Metrik *precision* untuk menghitung akurasi model terhadap prediksi positif dan kemampuan menghindari prediksi *false positive* dengan mengukur proporsi prediksi *true positive* (TP) terhadap prediksi positif lainnya menggunakan persamaan 3.10. Metrik *recall*, *sensitivity*, atau *true positive rate* menghitung proporsi prediksi positif terhadap jumlah data kelas positif yang sekaligus mengukur kemampuan model dalam memprediksi data kelas positif dengan menggunakan persamaan 3.11. Metrik *F1-score* adalah evaluasi yang menghitung rata-rata harmonik yang seimbang antara *precision* dan *recall* dengan menggunakan persamaan 3.12.

$$Accuracy = \frac{True\ Positives + True\ Negatives}{Total\ Predictions} \quad (3.9)$$

$$Precision = \frac{True\ Positives}{True\ Positives + False\ Positives} \quad (3.10)$$

$$Recall(Sensitivity) = \frac{True\ Positives}{True\ Positives + False\ Negatives} \quad (3.11)$$

$$F1_{score} = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (3.12)$$

3.9 Explainable Artificial Intelligence (XAI)

Dalam kasus penanganan medis, diperlukan adanya suatu alasan dan penjelasan yang kuat terhadap hasil diagnosis penyakit yang diberikan kepada

pasien, baik dari dokter, ahli, tenaga medis, hingga tak terkecuali, sistem komputer. Sebuah sistem diagnosis yang dibantu oleh komputer ini perlu memiliki tingkat interpretabilitas yang baik serta proses pengambilan keputusan medis yang dapat dipahami dan dipercaya oleh manusia, di samping faktor kualitas, efektivitas pengelolaan model, dan performa prediksi yang mencukupi (DARPA, n.d.).

XAI dikembangkan dengan tujuan untuk mengungkap permasalahan “*black-box*”, yaitu kesulitan yang dialami oleh sistem berbasis AI untuk menjelaskan proses atau alasan di balik keputusan yang diambil dalam suatu prediksi. Implementasi *Explainable Artificial Intelligence* (XAI) pada sebuah sistem mampu membantu membangun sebuah model diagnosis yang transparan, dapat dipercaya, serta memberikan penjelasan yang komprehensif terhadap perolehan hasil prediksi. Di sisi lain, beberapa model memiliki kompensasi *trade-off* antara akurasi dan interpretabilitas yang signifikan, di mana semakin mudah model tersebut dijelaskan, maka akurasi prediksi yang dihasilkan akan cenderung semakin rendah, begitu pula sebaliknya (Adadi & Berrada, 2018). Oleh karena itu, diperlukan adanya penyeimbangan antara kedua faktor tersebut sehingga model yang dihasilkan dapat optimal secara fungsi dan tingkat kepercayaan.

3.9.1 Framework XAI

Berdasarkan survei dari 223 penelitian yang dilakukan oleh Van Der Velden dkk. (2022), *framework* atau teknik-teknik yang digunakan pada implementasi XAI khususnya pada analisis citra medis dibagi menjadi tiga kriteria utama, yaitu *model-based* dan *post hoc*, *model-specific* dan *model-agnostic*, serta *global* dan *local explanation*. Rincian dari masing-masing teknik tersebut adalah sebagai berikut.

3.9.1.1 Model-based dan Post Hoc Explanation

Model-based mengacu kepada model-model dengan rancangan arsitektur yang sederhana, tradisional, dan memiliki proses pengambilan keputusan yang mudah dipahami secara langsung tanpa memerlukan teknik interpretasi tambahan. Kriteria *model-based* memaksa sebuah model untuk dapat dibangun dalam sebuah arsitektur yang sederhana melalui penyederhanaan fitur yang digunakan sehingga dapat dimengerti oleh pemahaman manusia. Tantangan implementasi XAI dengan teknik *model-based* adalah mengembangkan sebuah model yang cukup sederhana untuk dapat dengan mudah dipahami manusia dengan tetap mempertahankan performa akurasi prediksi yang tinggi karena *trade-off* yang telah dijelaskan

sebelumnya berdampak signifikan pada teknik ini. Teknik *post hoc* memahami alasan, hubungan, dan proses pengambilan keputusan yang dihasilkan dengan menganalisis model yang telah selesai melewati tahap pelatihan. Berbeda dengan *model-based* yang memaksa model untuk dapat dijelaskan dengan memodifikasi arsitektur yang ada di dalamnya, *post hoc* tidak mengubah arsitektur model untuk dapat menganalisis alasan pengambilan keputusan sehingga performa dan akurasi model tidak terpengaruh oleh implementasi teknik ini (Murdoch dkk., 2019).


3.9.1.2 *Model-specific* dan *Model-agnostic Explanation*

Hasil penjelasan model dari kriteria *model-specific* hanya terbatas kepada sebuah model tertentu sehingga tidak optimal apabila digunakan untuk menjelaskan model lain dengan arsitektur yang berbeda. Teknik-teknik yang digunakan memiliki parameter atau atribut tertentu yang hanya dapat menghasilkan penjelasan yang baik pada model yang sesuai. Berbeda dengan *model-specific*, kriteria *model-agnostic* mampu menganalisis suatu model hanya dengan melihat korelasi antara perubahan *input* dan *output* yang dihasilkan tanpa menggunakan parameter atau atribut yang bergantung pada arsitektur model yang digunakan. *Model-agnostic* menjelaskan model-model yang berbeda tanpa bergantung antara satu sama lain sehingga cenderung termasuk ke dalam kriteria *post hoc*.

3.9.1.3 *Global* dan *Local Explanation*

Ruang lingkup kriteria *global* mencakup penjelasan tentang bagaimana suatu dataset dapat berpengaruh kepada proses pengambilan keputusan oleh suatu model secara keseluruhan. Hasil analisis dapat menjadi acuan untuk menjelaskan pentingnya kontribusi data pada dataset dalam sebuah hubungan antara *input* yang digunakan beserta fitur yang diambil dengan *output* yang dihasilkan. Di sisi lain, jangkauan penjelasan kriteria *local* hanya terbatas kepada satu sampel *input* data dari keseluruhan dataset. Analisis dilakukan secara khusus hanya untuk memberikan penjelasan proses pengambilan keputusan dari data tersebut beserta bagian atau fitur yang berpengaruh terhadap hasil prediksi.

Berdasarkan penjelasan tersebut, teknik yang digunakan dalam implementasi XAI dikelompokkan oleh Van Der Velden dkk. (2022) sesuai dengan pembagian yang telah dijelaskan sebelumnya. Visualisasi dari klasifikasi tersebut ditunjukkan pada matriks di Tabel 3.3.



Tabel 3.3 Klasifikasi *Framework* Teknik XAI (Van Der Velden dkk., 2022)

3.9.2 Implementasi XAI dalam Analisis Citra

Van Der Velden dkk. (2022) membagi metode XAI dalam penanganan kasus analisis citra dengan *computer vision*, khususnya pada sektor medis menjadi tiga tipe, yaitu *visual*, *textual*, dan *example-based*. Rincian dari setiap tipe tersebut dijelaskan sebagai berikut.

3.9.2.1 Visual-based

Metode dengan tipe berbasis visual biasa disebut dengan *saliency mapping* yang menunjukkan bagian-bagian penting dari suatu citra yang berkontribusi terhadap hasil prediksi. Metode *saliency mapping* ini menggunakan beberapa pendekatan, seperti *backpropagation*, *perturbation*, dan *multiple instance learning-based*. Implementasi teknik *backpropagation-based* menggunakan gradien untuk menemukan kontribusi setiap piksel atau fitur terhadap hasil prediksi. Teknik ini dapat dilakukan dengan menggunakan algoritma *class activation mapping* (CAM), *gradient-weighted CAM* (Grad-CAM), *layer-wise relevance propagation* (LRP), Deep Shapley Additive Explanations (Deep SHAP), dan *trainable attention*. Teknik berbasis visual dengan pendekatan berbasis *perturbation* dilakukan dengan menambahkan “gangguan” ke suatu bagian dari citra asli untuk menganalisis dampak yang dihasilkan terhadap hasil prediksi. Teknik yang dapat dilakukan dengan menggunakan konsep metode ini adalah seperti *occlusion sensitivity*, *local interpretable model-agnostic explanations* (LIME), *meaningful perturbation*, dan *prediction difference analysis*. Terakhir, pendekatan *multiple instance learning-based* pada metode berbasis visual memanfaatkan *bags of instances* dengan *bags* yang

berlabel dan *instances* yang tidak berlabel. Pada kasus pengolahan citra, *bags* dapat merepresentasikan satu data citra keseluruhan yang berlabel, sedangkan *instances* yang ada di dalamnya berupa *patch*, yaitu kelompok piksel berisi sebagian kecil bagian atau *region* citra. Analisis dilakukan dengan pendekatan *patch-based*, yaitu dengan memberikan skor relevansi atau kontribusi dari setiap *patch* terhadap hasil prediksi yang memiliki korelasi positif. Metode ini menghasilkan sebuah peta penjelasan visual yang dapat membantu menjelaskan bagian citra yang menjadi alasan pengambilan keputusan model.

3.9.2.2 Textual-based

Metode berbasis tekstual dapat memberikan penjelasan secara deskriptif dari hasil prediksi dengan menjelaskan karakteristik sederhana hingga keseluruhan analisis dari suatu citra. Metode ini dibagi menjadi tiga tipe, yaitu *image captioning*, *image captioning with visual explanation*, dan *testing with concept attribution*. Metode pendekatan *image captioning* mampu memberikan keterangan atau penjelasan tekstual dari suatu data berdasarkan *ground truth* anotasi yang telah dibuat oleh manusia dan digunakan sebagai data pelatihan model dengan *long-short term memory* (LSTM). Selain itu, sebagai pengembangan dari teknik *image captioning* berbasis tekstual tersebut, dilakukan juga kombinasi dengan metode analisis berbasis visual yang juga menghasilkan penjelasan visual relevan, seperti *saliency map* yang mampu memperkuat alasan prediksi. Metode *testing with concept activation vectors* (TCAV) memanfaatkan pelabelan terhadap beberapa sampel data dengan konsep tingkat tinggi yang dapat dipahami oleh manusia. Pelabelan tersebut termasuk ke dalam kumpulan contoh konsep, sedangkan contoh random non-konsep juga digunakan sebagai label negatif selama proses analisis untuk menghitung sensitivitas model.

3.9.2.3 Example-based

Pada metode *example-based*, dilakukan perbandingan antara sampel atau contoh lain yang mirip atau relevan dengan data yang akan dianalisis serta berasal dari data yang telah diperoleh dari kasus sebelumnya. Sebagian besar teknik pada metode ini memanfaatkan *latent space* sebagai representasi data berdasarkan fitur yang dimiliki setiap data sekaligus menjadi media perbandingan sampel citra serta penjelasan hasil prediksi. Teknik *triplet network* menjelaskan alasan prediksi dengan menggunakan acuan tetangga terdekat dari data *input* di *latent space* berdasarkan

kemiripannya. Alasan prediksi yang diberikan berupa sampel data terdekat yang paling mirip dengan data yang sedang dianalisis. Penjelasan yang dijabarkan oleh teknik berbasis *influence functions* diperoleh dengan mencari contoh sampel citra yang paling berpengaruh terhadap fungsi yang digunakan untuk melakukan prediksi. Semakin besar dampak atau perbedaan hasil perhitungan fungsi setelah salah satu sampel *input* diubah atau tidak digunakan, maka semakin relevan pula sampel tersebut terhadap hasil prediksi, begitu pula sebaliknya. *Prototypes* memberikan pertimbangan berbasis kasus-kasus yang sebelumnya dengan melakukan pelatihan terhadap contoh yang paling representatif dari setiap kelas sebagai acuan untuk memberikan alasan prediksi suatu data. Semakin baik kualitas sampel yang diambil untuk merepresentasikan suatu kelas, maka akan semakin baik juga alasan prediksi data berdasarkan kemiripan antara keduanya dalam *latent space*.

3.9.3 Local Interpretable Model-Agnostic Explanations (LIME)

Ribeiro dkk. (2016) mengembangkan LIME sebagai teknik untuk menjelaskan hasil prediksi dari model klasifikasi yang bersifat *black-box* dengan membangun model *interpretable* yang lebih sederhana pada lingkup lokal di sekitar hasil prediksi yang sedang dianalisis. LIME merupakan metode yang fleksibel karena mampu menganalisis model klasifikasi berbasis teks maupun citra dengan penjelasan visual yang mudah dipahami oleh manusia tanpa perlu memperhatikan mekanisme dan fitur asli yang dipakai oleh suatu model. Prinsip utama LIME adalah dengan mencari model *interpretable* g yang mampu merepresentasikan model kompleks asli f pada suatu area lokal. Formulasi penjelasan $\xi(x)$ yang dihasilkan oleh LIME diperoleh dari *fidelity function* yang didefinisikan pada persamaan 3.13.

$$\xi(x) = \underset{g \in G}{\operatorname{argmin}} \mathcal{L}(f, g, \pi_x) + \Omega(g) \quad (3.13)$$

Di mana G adalah himpunan model sederhana seperti model linear *sparse* yang dapat diinterpretasikan dengan mudah oleh manusia, $\pi_x(z)$ adalah bobot kedekatan fitur citra terperturbasi z terhadap representasi asli x , dengan nilai bobot yang semakin besar apabila z semakin dekat dengan x , serta fungsi $\mathcal{L}$ yang digunakan untuk mengukur perbedaan representasi lokal dari model g terhadap model asli f pada z . Digunakan juga parameter $\Omega(g)$ untuk mengatur kompleksitas model g agar menjaga model tetap dapat diinterpretasikan dengan mudah melalui


metode regularisasi seperti Lasso. Oleh karena itu, untuk mendapatkan penjelasan prediksi yang paling optimal, dilakukan pelatihan model hingga memperoleh nilai kombinasi $\mathcal{L}(f, g, \pi_x)$ dan $\Omega(g)$ seminimal mungkin. Untuk mengoptimasi fungsi $\mathcal{L}$ tersebut, digunakan *local weighted square loss function* pada persamaan 3.14 yang menghitung perbedaan hasil prediksi model asli f terhadap prediksi model lokal g dengan bobotnya masing-masing.

$$\mathcal{L}(f, g, \pi_x) = \sum_{z, z' \in Z} \pi_x(z) (f(z) - g(z'))^2 \quad (3.14)$$

Proses pelatihan dilakukan dengan menambahkan perturbasi secara *random* dan *uniform* sampel z' dengan bobot π_x di sekitar representasi *interpretable* fitur x' . Pada kasus data citra, LIME akan membagi citra menjadi beberapa *superpixel*, yaitu gabungan piksel dengan kemiripan visual dalam satu *region*. Setiap *superpixel* tersebut akan memiliki representasi x' dan z' biner dengan nilai 1 apabila diaktifkan atau sama dengan citra asli dan 0 apabila dinonaktifkan atau berbeda dengan citra asli. Gabungan semua representasi biner dari *superpixel* citra asli adalah x' yang akan diperturbasi dengan menonaktifkan beberapa *superpixel* secara acak sehingga menghasilkan citra *interpretable* baru z' . Setiap z' memiliki representasi fitur z dengan bobot yang semakin tinggi apabila citra terperturbasi semakin mirip dengan gambar asli yang akan digunakan sebagai *input* prediksi model asli f . Hasil kontribusi *superpixel* diperoleh dengan melatih prediksi model linear g menggunakan z' dan bobot w yang diperoleh pada tahap sebelumnya menggunakan persamaan 3.15.

$$g(z') = w^T z' \quad (3.15)$$

Nilai koefisien w akan menentukan kontribusi dari setiap *superpixel* citra terhadap klasifikasi yang dihasilkan, di mana nilai positif memberikan kontribusi positif, nilai negatif memberikan kontribusi negatif, serta nilai 0 apabila *superpixel* tidak mempengaruhi prediksi. Terakhir, LIME akan menghasilkan suatu penjelasan visual kontribusi *superpixel* yang mudah dipahami berdasarkan perhitungan tersebut seperti pada contoh yang ditunjukkan di Gambar 3.5. Gambar pertama menunjukkan citra asli yang akan dianalisis, gambar kedua menjelaskan prediksi “gitar listrik”, gambar ketiga menjelaskan prediksi “gitar akustik”, dan gambar keempat menjelaskan prediksi “labrador” (Ribeiro dkk., 2016).



Gambar 3.5 Penjelasan Visual Hasil Prediksi LIME (Ribeiro dkk., 2016)

Sebagai salah satu pendekatan XAI, penjelasan hasil prediksi yang diberikan oleh LIME dapat dimanfaatkan untuk memilih model terbaik, mengoptimalkan tingkat kepercayaan, memperbaiki kualitas *classifier*, serta memahami kapan dan mengapa suatu *classifier* dapat atau tidak sebaiknya dipercaya. Bagi manusia, memiliki tingkat kepercayaan yang tinggi terhadap prediksi model menjadi faktor yang sangat penting karena konsekuensi dari setiap keputusan mampu memberikan dampak yang besar, seperti pada kasus diagnosis penyakit medis.

BAB IV

METODOLOGI PENELITIAN

4.1 Desain Penelitian


Penelitian ini akan mengembangkan sebuah sistem klasifikasi data citra menggunakan model berbasis *machine learning*. Kombinasi metode dan algoritma utama yang digunakan untuk ekstraksi fitur dan klasifikasi adalah Local Binary Pattern (LBP) dan Support Vector Machine (SVM). Kasus klasifikasi yang diambil adalah diagnosis penyakit tumor otak yang dianalisis dengan memanfaatkan media citra Magnetic Resonance Imaging (MRI) melalui dataset yang bersumber dari Kaggle dengan judul Brain Tumor Classification (MRI).

Tahapan yang dilakukan dalam pengolahan citra secara umum selama pembangunan model klasifikasi dapat divisualisasikan pada Gambar 4.1. Setelah proses pengumpulan data, dilakukan *preprocessing* untuk memperbaiki maupun meningkatkan kualitas citra sehingga dapat diproses pada tahap selanjutnya dengan optimal. Citra hasil *preprocessing* akan diolah di tahap ekstraksi fitur untuk mendapatkan representasi karakteristik citra yang akan digunakan sebagai data *input* pada tahap perancangan model klasifikasi. Teknik ekstraksi fitur yang digunakan mengimplementasikan LBP dan variannya, nLBP, α LBP, dan MB-LBP untuk memperoleh fitur tekstur citra. Pada tahap perancangan model utama, arsitektur SVM dengan kernel yang dimilikinya akan dilatih untuk mengklasifikasikan citra ke dalam empat kelas berbeda. Setelah proses pelatihan, validasi, dan pengujian model selesai, dilakukan tahap evaluasi untuk menganalisis performa yang dihasilkan oleh masing-masing varian LBP dan kernel SVM dalam melakukan klasifikasi data.

Selain SVM sebagai arsitektur model utama, dibangun juga model berbasis *machine learning* lainnya, yaitu k-Nearest Neighbor (KNN), Decision Tree (DT), Random Forest (RF), dan Naive Bayes (NB) serta model Convolutional Neural Network (CNN) yang berbasis *deep learning*. Model-model tersebut digunakan dalam tahap komparasi performa melalui perbandingan dengan model utama yang dihasilkan oleh kombinasi terbaik antara varian LBP dan kernel SVM.

Setelah tahap analisis dan perbandingan performa model selesai, model utama yang menghasilkan performa terbaik dari salah satu kombinasi varian LBP dan kernel SVM akan dianalisis pada tahap implementasi Explainable AI (XAI).


Local Interpretable Model-Agnostic Explanations (LIME) digunakan sebagai metode utama dalam menganalisis dan menjelaskan hasil prediksi model.



Gambar 4.1 Rencana Tahapan Penelitian

4.2 Data Penelitian

Objek yang digunakan dalam penelitian ini adalah dataset Brain Tumor Classification (MRI) yang bersumber dari Kaggle dan diunggah oleh Bhuvaji dkk. (2025). Dataset tersebut berisi total 3.264 data citra MRI yang telah dikelompokkan menjadi empat kelas berbeda, yaitu otak sehat dengan total 500 data, glioma dengan total 926 data, meningioma dengan total 937 data, dan pituitary dengan total 901 data. Dalam proses pengembangan, dataset akan dibagi ke dalam dua bagian, yaitu 80% data untuk pelatihan dan 20% data untuk pengujian. Contoh citra yang ada pada dataset tersebut ditampilkan pada Gambar 4.2.



Gambar 4.2 Contoh Citra Sampel Dataset (Bhuvaji dkk., 2025)

4.3 Alat Penelitian

4.3.1 Laptop

Sumber daya komputasi berupa perangkat keras yang digunakan pada penelitian ini untuk mengembangkan model dan menjalankan program adalah laptop dengan sistem operasi Linux Ubuntu 24.04.3 LTS (64-bit), *processor* AMD Ryzen 5 7640HS, dan RAM 16GB.

4.3.2 Perangkat Lunak

Perangkat lunak yang digunakan pada proses pengembangan model dari penelitian ini menggunakan bahasa pemrograman Python versi 3.12.3 beserta pustaka atau *library* yang relevan, seperti NumPy, Pandas, OpenCV, Matplotlib, dan Scikit-learn.

4.4 Tahapan Pengembangan Model

4.4.1 Preprocessing

Tahap persiapan dan pengolahan data mentah setelah akuisisi data dilakukan dengan tujuan untuk memaksimalkan kinerja metode-metode selanjutnya, seperti memperoleh kualitas fitur yang representatif dan klasifikasi yang akurat. Proses yang akan dilalui oleh citra sebelum masuk ke tahap ekstraksi fitur adalah *resizing*, *grayscale*, serta normalisasi. Proses *resizing* dilakukan dengan menyeragamkan ukuran citra untuk memastikan konsistensinya, *grayscale* dengan melakukan konversi kanal warna citra dari RGB ke citra abu-abu untuk menyederhanakan komputasi, serta normalisasi dengan mengubah skala intensitas piksel dari 0-255 ke 0-1 untuk menghindari bias.

4.4.2 Ekstraksi Fitur

Berdasarkan penjelasan pada sub-bab 3.6, metode LBP klasik beserta tiga variannya, yaitu nLBP, α LBP, dan MB-LBP digunakan pada tahap ekstraksi fitur

untuk memperoleh representasi tekstur citra. Proses yang dilakukan pada teknik LBP klasik diawali dengan menentukan nilai radius R dan jumlah piksel tetangga P . Selain metode LBP klasik, digunakan juga tiga varian dari metode tersebut, yaitu nLBP, α LBP, dan MB-LBP. Setiap variasi parameter yang akan digunakan oleh masing-masing metode ditentukan terlebih dahulu untuk mengawali proses komputasi dan pencarian representasi tekstur. Teknik nLBP akan menentukan nilai parameter d sebagai jarak perbandingan antar tetangga piksel, teknik α LBP menentukan nilai parameter α untuk menemukan anggota dari piksel tetangga yang akan dibandingkan satu sama lain, sedangkan MB-LBP menentukan ukuran blok s yang menentukan anggota *sub-region* piksel untuk dihitung rata-ratanya sebagai acuan perbandingan. Perbandingan nilai intensitas dilakukan antara pusat dengan seluruh tetangganya untuk mendapatkan nilai dari setiap digit biner. Masing-masing digit biner yang diperoleh tersebut akan digabungkan menjadi satu rangkaian angka biner utuh dan dikonversi ke bilangan desimal yang menjadi representasi fitur tekstur citra. Pelabelan setiap piksel atau blok dilakukan berdasarkan metode ekstraksinya masing-masing dengan mengimplementasikan pendekatan *uniform patterns* bagi metode yang memungkinkan untuk menyederhanakan dimensi fitur dan meningkatkan efektivitas komputasi. Jumlah kemunculan dari setiap fitur dalam sebuah citra digunakan sebagai data penyusun histogram fitur tekstur citra dengan karakteristik dan labelnya masing-masing. Representasi histogram ini akan menjadi fitur vektor yang digunakan pada proses klasifikasi model. Dari ketiga varian dan masing-masing parameter yang digunakan, akan dipilih satu kombinasi terbaik antara teknik ekstraksi fitur serta parameter yang digunakan dengan arsitektur klasifikasi SVM yang menghasilkan performa paling baik dari keseluruhan konfigurasi.

4.4.3 Klasifikasi

Setiap fitur vektor yang diperoleh dari tahap ekstraksi digunakan sebagai *input* pada tahap pengembangan model klasifikasi, seperti yang telah dijelaskan pada sub-bab 3.7. Model dengan arsitektur SVM akan membagi data berdasarkan fitur representasinya ke dalam salah satu dari empat kelas tumor otak. Proses pelatihan model menggunakan data pelatihan dilakukan berdasarkan parameter-parameter yang telah dipilih sebelumnya. Performa model yang dihasilkan diukur berdasarkan kemampuan model memprediksi kelas dari data pengujian. Apabila diperlukan, proses *hyperparameter tuning* dilakukan dengan mencari kombinasi nilai C , γ ,

serta fungsi *kernel* yang digunakan hingga model menunjukkan performa klasifikasi yang paling optimal.

Selain pengembangan model SVM, model berbasis *machine learning* sederhana lainnya yang meliputi KNN, DT, RF, dan NB juga dikembangkan sebagai pembandingan performa. Model-model tersebut digunakan sebagai acuan penilaian apakah arsitektur SVM dan kernelnya mampu menghasilkan performa klasifikasi yang kompetitif apabila dibandingkan dengan arsitektur *machine learning* lain dengan karakteristik yang berbeda. Model dengan arsitektur CNN juga dikembangkan untuk menjadi dasar untuk perbandingan performa model berbasis *deep learning*. Model ini juga akan membuktikan apakah arsitektur kombinasi *machine learning* sederhana dengan LBP dan SVM dapat bersaing dengan model-model *deep learning* yang lebih kompleks. Perbandingan tersebut dilakukan dengan memperhatikan faktor performa dari sisi efisiensi komputasi maupun akurasi klasifikasi. Proses pelatihan, validasi, dan pengujian selama pengembangan setiap model juga akan dianalisis dan dibandingkan berdasarkan parameter tertentu, seperti kebutuhan data, waktu, dan sumber daya komputasi. Beberapa metrik juga digunakan sebagai parameter perbandingan performa yang dilakukan pada tahap evaluasi model.

4.5 Evaluasi Model

Analisis performa klasifikasi model SVM dan arsitektur lainnya diukur pada tahap evaluasi berdasarkan beberapa metrik. *Confusion matrix* digunakan untuk mengetahui jumlah keberhasilan dan kegagalan model dalam memprediksi kelas data. Metrik evaluasi *accuracy*, *precision*, *recall*, dan *F1-score* digunakan untuk mengetahui kualitas model dengan lebih komprehensif. Penjelasan dari masing-masing metrik evaluasi serta peran dan fungsinya telah dijabarkan pada sub-bab 3.8.

4.6 Implementasi Explainable AI (XAI)

Pada tahap akhir, model SVM yang menghasilkan performa terbaik akan melewati proses implementasi XAI. Tujuan dari tahap ini adalah untuk memperoleh penjelasan hasil prediksi melalui visualisasi area citra MRI yang memberikan kontribusi terbesar terhadap hasil diagnosis. Hasil pelatihan model SVM digunakan

sebagai acuan utama pada metode LIME untuk mencari alasan diagnosis penyakit. Salah satu citra MRI otak manusia yang akan dianalisis dibagi menjadi beberapa bagian *superpixel*. Setiap *superpixel* tersebut akan memiliki representasi *interpretable* biner sesuai dengan kondisi aktivasinya, yaitu 1 untuk bagian citra yang sama dengan gambar asli dan 0 untuk bagian citra yang terperturbasi. *Superpixel* yang dinonaktifkan akan mengganti nilai intensitas setiap piksel di *region* tersebut, seperti mengubah ke nilai rata-rata intensitas piksel citra yang menyebabkan nilai representasi *interpretable* di area tersebut menjadi 0. Perturbasi terhadap pola representasi tersebut diaplikasikan secara *random* di antara semua *superpixel* sehingga akan menghasilkan banyak citra dengan visual yang berbeda-beda. Dari setiap citra terperturbasi tersebut akan dilakukan ekstraksi fitur menggunakan varian LBP terbaik yang digunakan sebagai data pelatihan model SVM. Bobot kedekatan dari masing-masing sampel tersebut dihitung dengan nilai yang semakin besar apabila fitur citra terperturbasi semakin mirip dengan fitur citra asli. Model linear *sparse* lokal dengan regularisasi dilatih di sekitar sampel berdasarkan fitur-fitur representasi *superpixel* citra terperturbasi. Model sederhana tersebut dibangun sebagai aproksimasi model asli dalam lingkup lokal dari sampel data hasil prediksi. Proses pelatihan model bertujuan untuk mencari nilai koefisien bobot yang menjadi representasi kontribusi *superpixel* terhadap hasil diagnosis penyakit. Penjelasan visual ditampilkan dengan mengacu pada nilai koefisien bobot dari masing-masing *superpixel* yang telah dilatih model. Beberapa *superpixel* dengan nilai bobot tertinggi akan ditampilkan sebagai penjelasan perolehan diagnosis dengan menjelaskan area yang paling signifikan bagi hasil prediksi.

BAB V

JADWAL PENELITIAN

Penelitian ini dilakukan berdasarkan jadwal yang disusun untuk memberikan gambaran waktu pelaksanaan setiap tahap penelitian, mulai dari tinjauan pustaka, penyusunan naskah, implementasi, hingga pengujian laporan akhir. Rincian jadwal penelitian ditunjukkan pada Tabel 5.1.

Tabel 5.1 Jadwal Penelitian

Kegiatan Penelitian	Agustus					September					Oktober					November				Desember				
	1	2	3	4	5	1	2	3	4	5	1	2	3	4	5	1	2	3	4	1	2	3	4	5
Tinjauan Pustaka																								
Penyusunan Proposal																								
Pengujian Proposal																								
Implementasi																								
Analisis Hasil																								
Penyusunan Laporan Akhir																								
Pengujian Laporan Akhir																								

REFERENSI

- Adadi, A., & Berrada, M. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, 6, 52138–52160. <https://doi.org/10.1109/access.2018.2870052>
- Ahonen, T., Hadid, A., & Pietikäinen, M. (2004). Face Recognition with Local Binary Patterns. In *Lecture notes in computer science* (pp. 469–481). https://doi.org/10.1007/978-3-540-24670-1_36
- Aisyah, D. N., Setiawan, A. H., Lokopessy, A. F., Faradiba, N., Setiaji, S., Manikam, L., & Kozlakidis, Z. (2024). The Information and Communication Technology Maturity Assessment at Primary Health Care Services Across 9 Provinces in Indonesia: Evaluation Study. *JMIR Medical Informatics*, 12, e55959. <https://doi.org/10.2196/55959>
- Alpaydin, E. (2010). *Introduction to machine learning*. MIT Press (MA).
- American Cancer Society. (2020). *What Are Adult Brain and Spinal Cord Tumors?*. Diakses 18 September 2025, dari <https://www.cancer.org/cancer/types/brain-spinal-cord-tumors-adults/about/what-are-brain-spinal-tumors.html>
- Archana, R., & Jeevaraj, P. S. E. (2024). Deep Learning Models for Digital Image Processing: A Review. *Artificial Intelligence Review*, 57(1). <https://doi.org/10.1007/s10462-023-10631-z>
- Azhar, S., & Chong, L. R. (2022). Clinician's Guide to The Basic Principles of MRI. *Postgraduate Medical Journal*, 99(1174), 894-903. <https://doi.org/10.1136/pmj-2022-141998>
- Azzeh, M., Elsheikh, Y., Nassif, A. B., & Angelis, L. (2022). Examining the performance of kernel methods for software defect prediction based on support vector machine. *Science of Computer Programming*, 226, 102916. <https://doi.org/10.1016/j.scico.2022.102916>
- Badillo, S., Banfai, B., Birzele, F., Davydov, I. I., Hutchinson, L., Kam-Thong, T., Siebourg-Polster, J., Steiert, B., & Zhang, J. D. (2020). An introduction to

- machine learning. *Clinical Pharmacology & Therapeutics*, 107(4), 871–885.
<https://doi.org/10.1002/cpt.1796>
- Basthikodi, M., Chaithrashree, M., Shafeeq, B. M. A., & Gurple, A. P. (2024). Enhancing multiclass brain tumor diagnosis using SVM and innovative feature extraction techniques. *Scientific Reports*, 14(1).
<https://doi.org/10.1038/s41598-024-77243-7>
- Bhattacharjee, S., Prakash, D., Kim, C., Kim, H., & Choi, H. (2022). Texture, Morphology, and Statistical Analysis to Differentiate Primary Brain Tumors on Two-Dimensional Magnetic Resonance Imaging Scans using Artificial Intelligence Techniques. *Healthcare Informatics Research*, 28(1), 46–57.
<https://doi.org/10.4258/hir.2022.28.1.46>
- Bhuvaji, S., Kadam, A., Bhumkar, P., Dedge, S., & Kanchan, S. (2025). Brain Tumor Classification (MRI) [Data set]. Kaggle.
<https://doi.org/10.34740/KAGGLE/DSV/12745533>
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer Verlag.
- Chen, C., Isa, N. A. M., & Liu, X. (2024). A Review of Convolutional Neural Network Based Methods for Medical Image Classification. *Computers in Biology and Medicine*, 185, 109507.
<https://doi.org/10.1016/j.compbiomed.2024.109507>
- Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/bf00994018>
- Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)* (pp. 886-893 vol. 1).
- Defense Advanced Research Project Agency (DARPA). (n.d.). *XAI: Explainable Artificial Intelligence*. Diakses 14 November 2025, dari <https://www.darpa.mil/research/programs/explainable-artificial-intelligence>

- Dhamara, A. S., Purnama, S. I., & Afandi, M. A. (2025). Implementasi Arsitektur U-Net Untuk Segmentasi Tumor Otak Otomatis Pada Citra MRI Dengan Data Pengujian Asli. *e-Proceeding of Engineering*, 12(4), 4608–4616.
- Ferlay, J., Ervik, M., Lam, F., Laversanne, M., Colombet, M., Mery, L., Piñeros, M., Znaor, A., Soerjomataram, I., & Bray, F. (2024). Global Cancer Observatory: Cancer Today. *Lyon, Prancis: International Agency for Research on Cancer*. Diakses dari <https://gco.iarc.who.int/today> pada 20 Juni 2025.
- Gonzalez, R. C., & Woods, R. E. (2017). *Digital Image Processing, Global Edition*. Pearson Higher Education.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- Hafshejani, S. F., & Moabarfard, Z. (2022). A new trigonometric kernel function for support vector machine. *Iran Journal of Computer Science*, 6(2), 137–145. <https://doi.org/10.1007/s42044-022-00130-9>
- Johns Hopkins Medicine. (n.d.). *Brain Tumors and Brain Cancer*. Diakses 18 September 2025, dari <https://www.hopkinsmedicine.org/health/conditions-and-diseases/brain-tumor>
- Johns Hopkins Medicine. (n.d.). *Magnetic Resonance Imaging (MRI)*. Diakses 18 September 2025, dari <https://www.hopkinsmedicine.org/health/treatment-tests-and-therapies/magnetic-resonance-imaging-mri>
- Jun, Z. (2021). The development and application of Support Vector Machine. *Journal of Physics Conference Series*, 1748(5), 052006. <https://doi.org/10.1088/1742-6596/1748/5/052006>
- Kaplan, K., Kaya, Y., Kuncan, M., & Ertunç, H. M. (2020). Brain Tumor Classification Using Modified Local Binary Patterns (LBP) Feature Extraction Methods. *Medical Hypotheses*, 139, 109696. <https://doi.org/10.1016/j.mehy.2020.109696>
- Liao, S., Zhu, X., Lei, Z., Zhang, L., & Li, S.Z. (2007). Learning Multi-scale Block Local Binary Patterns for Face Recognition. *Lecture Notes in Computer Science*, 4642, 828–837. https://doi.org/10.1007/978-3-540-74549-5_87

- Liu, C. (2024). A Review of Digital Image Processing Techniques and Future Prospects. *International Journal of Computer Science and Information Technology*, 4(3), 223–233. <https://doi.org/10.62051/ijcsit.v4n3.22>
- Liu, T. T. (2019). MRI in Systems Medicine. *WIREs Systems Biology and Medicine*, 12(1). <https://doi.org/10.1002/wsbm.1463>
- Maggioni, F., & Spinelli, A. (2024). A Novel Robust Optimization Model for Nonlinear Support Vector Machine. *European Journal of Operational Research*. <https://doi.org/10.1016/j.ejor.2024.12.014>
- Mayo Clinic. (2024). *Brain Tumor*. Diakses 16 September 2025, dari <https://www.mayoclinic.org/diseases-conditions/brain-tumor/symptoms-causes/syc-20350084>
- Murdoch, W. J., Singh, C., Kumbier, K., Abbasi-Asl, R., & Yu, B. (2019). Definitions, Methods, and Applications in Interpretable Machine Learning. *Proceedings of the National Academy of Sciences*, 116(44), 22071–22080. <https://doi.org/10.1073/pnas.1900654116>
- National Cancer Institute. (2023). *Brain and Spine Tumor Anatomy and Functions*. Diakses 16 September 2025, dari <https://www.cancer.gov/rare-brain-spine-tumor/tumors/anatomy>
- Ojala, T., Pietikainen, M., & Maenpaa, T. (2002). Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7), 971–987. <https://doi.org/10.1109/tpami.2002.1017623>
- Özkaraca, O., Bağrıaçık, O. İ., Gürüler, H., Khan, F., Hussain, J., Khan, J., & Laila, U. E. (2023). Multiple Brain Tumor Classification with Dense CNN Architecture Using Brain MRI Images. *Life*, 13(2), 349. <https://doi.org/10.3390/life13020349>
- Russell, S., & Norvig, P. (2021). *Artificial Intelligence: A Modern Approach, Fourth Edition, Global Edition*. Pearson Higher Ed.

- Seetha, J., & Raja, S. S. (2018). Brain Tumor Classification using Convolutional Neural Networks. *Biomedical & Pharmacology Journal*, 11(3), 1457–1461. <https://doi.org/10.13005/bpj/1511>
- Sinaga, M. R. T., Tampubolon, B., Daulay, N. H., Triana, D., Hani, A., Simanjuntak, F. A., & Arnita, A. (2025). Development of Deep Learning Model Based on Convolutional Neural Network (CNN) for Brain Tumor Classification using MRI Images. *EduMatika: Jurnal MIPA*, 5(2), 27–34. <https://doi.org/10.56495/emju.v5i2.1105>
- Sze, V., Chen, Y., Yang, T., & Emer, J. (2017). Efficient Processing of Deep Neural Networks: A Tutorial and Survey. *arXiv (Cornell University)*. <https://doi.org/10.48550/arxiv.1703.09039>
- Vapnik, V. N., & Chervonenkis, A. Y. (1974). Theory of Pattern Recognition. *Moscow: Nauka*.
- Yang, Q., Zhang, H., Xia, J., & Zhang, X. (2021). Evaluation of Magnetic Resonance Image Segmentation in Brain Low-Grade Gliomas using Support Vector Machine and Convolutional Neural Network. *Quantitative Imaging in Medicine and Surgery*, 11(1), 300–316. <https://doi.org/10.21037/qims-20-783>