


PROPOSAL SKRIPSI

**KLASIFIKASI CITRA PENYAKIT TUMOR OTAK MANUSIA PADA CITRA
MAGNETIC RESONANCE IMAGE MENGGUNAKAN LOCAL BINARY
PATTERN DAN SUPPORT VECTOR MACHINE**



Andyan Yogawardhana

21/482180/PA/21030

**PROGRAM STUDI S1 ILMU KOMPUTER
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA
YOGYAKARTA**

2025

ABSTRAK

KLASIFIKASI CITRA PENYAKIT TUMOR OTAK MANUSIA PADA CITRA MAGNETIC RESONANCE IMAGE MENGGUNAKAN LOCAL BINARY PATTERN DAN SUPPORT VECTOR MACHINE

Oleh

Andyan Yogawardhana

21/482180/PA/21030

Kata Kunci:

DAFTAR ISI

DAFTAR ISI.....	2
BAB 1 PENDAHULUAN.....	3
1.1. Latar Belakang.....	3
1.2. Rumusan Masalah.....	4
1.3. Batasan Masalah.....	4
1.4. Tujuan Penelitian.....	4
1.5. Manfaat Penelitian.....	4
1.6. Sistematika Penelitian.....	4
BAB II TINJAUAN PUSTAKA.....	6
BAB III DASAR TEORI.....	7

BAB 1

PENDAHULUAN

1.1. Latar Belakang

Otak merupakan bagian dari *central nervous system* (CNS) atau sistem saraf pusat, sekaligus menjadi salah satu organ tubuh terpenting yang bertugas untuk mengatur dan mengendalikan sebagian besar fungsi penting tubuh manusia (National Cancer Institute, 2023). Gangguan maupun kerusakan pada sistem saraf pusat dapat mengganggu fungsi vital tersebut sehingga mampu memberikan dampak yang signifikan bagi kesehatan dan kehidupan seseorang. Salah satu kelainan yang dapat menyerang sistem saraf pusat, khususnya otak, adalah tumor otak (Özkaraca dkk., 2023). Tumor otak adalah sebuah kelainan seluler yang ditandai dengan pembentukan, pertumbuhan, atau akumulasi sel secara tidak normal di bagian otak dengan karakteristik yang beragam, tergantung pada jenis dan tingkat keganasannya (Basthikodi dkk., 2024). Penyakit tumor otak pada manusia menjadi salah satu kondisi medis yang perlu mendapatkan perhatian serius karena berpotensi besar memberikan dampak yang fatal terhadap para penderitanya, mulai dari penurunan kualitas hidup hingga risiko kematian. Berdasarkan data yang diperoleh dari Global Cancer Observatory di tahun 2022, dari total 5.738 kasus penyakit tumor otak yang terdiagnosis di Indonesia, angka kematian yang ditunjukkan mencapai 5.259 jiwa atau lebih dari 91% dari kasus terdiagnosis (Ferlay dkk., 2024). Tingginya persentase kematian ini menunjukkan bahwa upaya penanganan dini sangat diperlukan agar tenaga medis dapat memberikan tindakan pengobatan yang lebih cepat dan tepat. Dengan adanya penanganan dini tersebut, harapannya dapat meningkatkan peluang kesembuhan pasien sekaligus menekan persentase korban meninggal akibat penyakit ini (Naseer dkk., 2021).

Penanganan penyakit tumor otak dapat dilakukan dengan berbagai cara, terlebih lagi melalui inovasi teknologi pencitraan medis yang dapat mendukung upaya tersebut. Citra yang sering digunakan adalah citra Magnetic Resonance Imaging (MRI) yang mampu menampilkan informasi mendetail tentang anatomi tubuh manusia tanpa perlu melewati prosedur invasif (Liu, 2019). Citra MRI juga dapat memberikan informasi penting tentang kondisi kesehatan di bagian tubuh tertentu, seperti stroke, demensia, serta tumor yang ada pada otak pasien sehingga dapat digunakan sebagai media utama dalam proses deteksi dan diagnosis penyakit.

Meskipun demikian, proses diagnosis penyakit yang memanfaatkan citra MRI secara tradisional masih bergantung pada keahlian analisis tenaga medis. Metode ini juga memiliki beberapa kekurangan, seperti membutuhkan waktu yang panjang dan tenaga yang besar, berpotensi menimbulkan perbedaan hasil analisis antara pengamat satu dengan yang lainnya, serta memungkinkan adanya ketidakakuratan interpretasi citra (Bhattacharjee dkk., 2022). Oleh karena itu, pemanfaatan pengolahan citra medis secara digital dengan bantuan komputer menjadi penting karena dapat membantu mengatasi permasalahan tersebut dengan memaksimalkan ketepatan diagnosis dan memberikan hasil analisis yang dapat menjadi bahan pertimbangan tambahan dalam pengambilan keputusan tenaga medis.

Salah satu metode implementasi pengolahan citra medis dapat dilakukan melalui metode penglihatan komputer (*computer vision*) dan pembelajaran mesin (*machine learning*), khususnya dalam bidang *computer vision*. Model yang dihasilkan dapat membantu tenaga medis dalam memproses dan menganalisis data citra MRI untuk melakukan diagnosis melalui deteksi dan klasifikasi tumor berdasarkan fitur-fitur yang ada pada citra tersebut. Penelitian yang dilakukan oleh Seetha dan Raja (2018) menunjukkan bahwa sistem diagnosis penyakit tumor otak berbasis citra MRI menunjukkan hasil yang menjanjikan. Model tersebut dapat menghasilkan tingkat akurasi yang tinggi, yaitu sebesar 97.5% dengan mengimplementasikan arsitektur Convolutional Neural Network (CNN) yang umum digunakan untuk menganalisis data citra. Namun demikian, untuk dapat mencapai tingkat akurasi yang tinggi, arsitektur *deep learning* seperti CNN membutuhkan sumber daya komputasi yang besar, waktu *training* yang lama, serta perangkat komputasi dengan performa dan spesifikasi yang tinggi seperti Graphics Processing Unit (GPU) (Sze dkk., 2017). Selain itu, jumlah data yang dibutuhkan dalam tahap pembangunan model juga relatif besar untuk dapat memperoleh angka akurasi yang optimal sekaligus menghindari kasus *overfitting* selama proses *training*. Dari sisi proses pengambilan keputusan dan perolehan hasil komputasi, arsitektur CNN yang kompleks juga memiliki mekanisme pengambilan keputusan yang tidak mudah untuk dipahami secara langsung oleh manusia (Adadi dan Berrada, 2018). Pada bidang kesehatan, keterbatasan tersebut menjadi salah satu faktor krusial yang perlu diperhatikan karena tenaga medis perlu memiliki interpretasi yang kuat dan masuk

akal untuk dipertanggungjawabkan dalam pengambilan hasil diagnosis penyakit pasien.

Meskipun dapat menghasilkan performa klasifikasi yang tinggi, model berbasis *deep learning* masih memiliki beberapa kekurangan seperti yang telah dijelaskan sebelumnya. Kekurangan terkait dengan besarnya kebutuhan ketersediaan data dan sumber daya komputasi tersebut berkaitan dengan penelitian yang dilakukan oleh Aisyah dkk. (2024) yang menemukan bahwa tingkat kematangan teknologi informasi dan komunikasi (ICT) dari fasilitas kesehatan di Indonesia masih belum terdistribusi dengan baik. Fasilitas kesehatan di wilayah urban atau perkotaan secara umum masih lebih unggul dan layak jika dibandingkan dengan fasilitas yang ada di wilayah rural atau pelosok apabila dilihat dari sisi sumber daya manusia, integrasi aplikasi atau sistem informasi, ketersediaan perangkat, serta kelayakan infrastruktur. Kondisi ini membuka peluang kepada metode alternatif selain *deep learning* untuk dapat memiliki sistem yang tetap optimal meskipun dihadapkan dengan keterbatasan tersebut.

Dalam kasus pengembangan sistem diagnosis tumor otak, metode ekstraksi fitur sederhana dan algoritma klasifikasi tradisional masih relevan untuk dikembangkan, terutama sebagai salah satu alternatif untuk menghadapi permasalahan keterbatasan infrastruktur, seperti sumber daya komputasi dan data referensi yang terbatas. Salah satu metode ekstraksi fitur yang dapat memperoleh representasi pola tekstur lokal citra adalah Local Binary Pattern (LBP) yang memiliki keunggulan dalam hal komputasi yang cepat dan ringan serta ketahanan terhadap variasi pencahayaan dan rotasi citra (Ojala dkk., 2002). Pemilihan algoritma klasifikasi yang sesuai dengan metode ekstraksi fitur yang digunakan juga penting untuk dapat memaksimalkan performa model yang dihasilkan. Dalam hal ini, Support Vector Machine (SVM) adalah salah satu algoritma klasifikasi *machine learning* sederhana yang dapat dikombinasikan dengan LBP untuk memperoleh model klasifikasi yang optimal. SVM diperkenalkan oleh Cortes dan Vapnik (1995) melalui sebuah penelitian dengan judul *Support-Vector Networks* yang berisi penjelasan tentang cara kerja SVM dalam melakukan pemisahan dua kelas data melalui *hyperplane* di antara dua *support vectors* dari kelas yang berbeda dengan *margin* maksimum. Algoritma SVM dapat melakukan tugas analisis dan klasifikasi dengan sumber daya komputasi yang ringan serta menghasilkan performa yang baik

saat jumlah data yang digunakan terbatas (Yang dkk., 2021). SVM juga memiliki proses pengambilan keputusan yang lebih transparan serta mudah diinterpretasikan. Dengan demikian, kombinasi metode ekstraksi fitur LBP dan algoritma klasifikasi SVM tersebut diharapkan dapat menghasilkan sistem diagnosis tumor otak yang sederhana, efisien, dan akurat serta dapat mengatasi permasalahan yang muncul pada model berbasis CNN yang telah dijelaskan sebelumnya.

Berdasarkan permasalahan tersebut, dapat disimpulkan bahwa penanganan dini pasien tumor otak menjadi salah satu upaya yang sangat penting untuk dilakukan secara cepat, tepat, dan akurat. Dalam rangka mendukung upaya tersebut, bantuan komputer untuk melakukan diagnosis dari hasil pemindaian citra MRI menjadi salah satu hal yang membantu meningkatkan peluang keselamatan pasien. Walaupun dapat mencapai performa dan akurasi yang tinggi, metode sebelumnya yang telah mengimplementasikan CNN memiliki beberapa keterbatasan dan kurang memungkinkan untuk dapat diimplementasikan oleh fasilitas kesehatan yang belum memiliki infrastruktur dan perangkat yang memadai. Oleh karena itu, penelitian ini berfokus pada pengembangan sistem diagnosis menggunakan LBP sebagai ekstraksi fitur dan SVM sebagai algoritma klasifikasi yang dapat melengkapi kekurangan pada sistem dari penelitian sebelumnya. Model *machine learning* sederhana yang akan dikembangkan harapannya dapat menghasilkan sistem diagnosis tumor otak yang tidak membutuhkan data dalam jumlah besar, waktu klasifikasi sistem yang cepat, dan kebutuhan sumber daya komputasi yang ringan. Model tersebut juga diharapkan dapat menghasilkan performa dan akurasi diagnosis yang cukup baik sehingga dapat membantu dalam upaya penanganan pasien serta dapat menjadi bahan evaluasi tambahan bagi tenaga medis, terlebih lagi pada fasilitas-fasilitas kesehatan di Indonesia yang masih memiliki kendala data dan sumber daya yang kurang mencukupi.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, penelitian ini merumuskan permasalahan tentang bagaimana performa model yang dibangun dengan kombinasi antara metode ekstraksi fitur dan algoritma klasifikasi sederhana apabila dibandingkan dengan model yang lebih kompleks. Berkaitan dengan hal tersebut, rumusan masalah pada penelitian ini juga membahas secara spesifik tentang bagaimana implementasi LBP sebagai metode ekstraksi fitur dan SVM sebagai

algoritma klasifikasi model untuk melakukan diagnosis penyakit tumor otak manusia berbasis citra MRI.

1.3. Batasan Masalah

Batasan masalah yang ditetapkan pada penelitian ini adalah sebagai berikut:

1. Data yang digunakan pada penelitian ini adalah dalam bentuk citra MRI otak manusia, diperoleh dari dataset publik yang bersumber dari Kaggle dengan judul [REDACTED].
2. Metode dan algoritma yang digunakan dalam proses pengembangan model adalah Local Binary Pattern (LBP) [varian nLBP dan α LBP + PCA] untuk ekstraksi fitur dan Support Vector Machine (SVM) [varian KSVM] untuk klasifikasi ke dalam kategori multiclass.

1.4. Tujuan Penelitian

Tujuan dari dilakukannya penelitian ini adalah untuk mengembangkan model *machine learning* yang dapat membantu proses diagnosis penyakit tumor otak manusia dengan mengimplementasikan LBP untuk melakukan ekstraksi fitur dari citra MRI dan algoritma SVM untuk mengolah data hasil ekstraksi fitur dan mengklasifikasikan hasil diagnosis ke dalam empat kategori tumor otak. Model tersebut juga akan melewati proses evaluasi dengan menggunakan matriks *accuracy*, *precision*, *recall*, dan *F1-score* untuk memperoleh gambaran dari tingkat akurasi dan efektivitas klasifikasi.

1.5. Manfaat Penelitian

Penelitian ini dilakukan dengan harapan agar dapat memberikan manfaat dan kontribusi secara ilmiah dengan membantu tenaga medis dan akademisi dalam mempelajari metode-metode *machine learning*, khususnya dalam lingkup penglihatan komputer dan klasifikasi citra medis. Selain itu, hasil model klasifikasi yang diperoleh dari penelitian ini juga diharapkan dapat diimplementasikan secara langsung untuk membantu tenaga medis dalam melakukan upaya diagnosis dini dari penyakit tumor otak pada pasien secara ringan, cepat, dan akurat.

1.6. Sistematika Penelitian

Naskah laporan pada proposal penelitian ini akan disusun berdasarkan sistematika berikut:

BAB I PENDAHULUAN

Bab ini berisi uraian tentang latar belakang penelitian, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, dan sistematika penelitian.

BAB II TINJAUAN PUSTAKA

Bab ini berisi tinjauan pustaka dan pemaparan tentang penelitian-penelitian terdahulu yang relevan dengan topik klasifikasi citra tumor otak manusia.

BAB III DASAR TEORI

Bab ini berisi penjelasan teori-teori yang digunakan sebagai dasar acuan implementasi metodologi yang digunakan selama proses penelitian dan pengembangan model klasifikasi.

BAB IV METODOLOGI

Bab ini berisi rincian metode yang digunakan serta tahapan yang dilakukan pada penelitian klasifikasi citra tumor otak manusia dari tahap pengumpulan data hingga pengembangan model.

BAB V JADWAL PENELITIAN

Bab ini berisi rincian jadwal pelaksanaan setiap tahapan penelitian yang akan dilakukan, khususnya dalam bentuk matriks perencanaan penelitian dimulai dari tinjauan pustaka, pelaksanaan, hingga penyusunan laporan penelitian.

BAB II

TINJAUAN PUSTAKA

Pada kasus diagnosis penyakit tumor otak, beberapa penelitian telah dilakukan untuk mengembangkan suatu model yang dapat melakukan tugas deteksi maupun klasifikasi. Berbagai metode *computer vision* yang memanfaatkan algoritma-algoritma *deep learning* maupun *machine learning* juga telah dilakukan untuk mengolah citra MRI yang utamanya digunakan untuk menganalisis keberadaan tumor pada otak manusia. Salah satu metode yang sering digunakan untuk menangani permasalahan tersebut adalah Convolutional Neural Network (CNN) yang berbasis *deep learning*. Penelitian terdahulu yang mengimplementasikan metode CNN untuk mengatasi permasalahan diagnosis tumor otak dengan bantuan computer-aided diagnostic (CAD) terotomasi salah satunya telah dilakukan oleh Özkaraca dkk. (2023). Penelitian tersebut mengembangkan dan membandingkan beberapa arsitektur berbasis *deep learning* populer, yaitu Basic CNN, VGG16 Net, dan DenseNet, serta mengajukan sebuah model dengan arsitektur baru, yaitu Modified CNN yang dikembangkan untuk mengatasi kekurangan dan meningkatkan performa dari ketiga model sebelumnya. Pengembangan semua model tersebut menggunakan hasil kombinasi dataset yang diperoleh dari Kaggle, yaitu figshare, SARTAJ dataset, dan Br35H. Dengan total data sebanyak 7.021 citra Magnetic Resonance Imaging (MRI) otak manusia, dataset terbagi menjadi 4 kelas, yaitu *glioma*, *meningioma*, *pituitary*, dan otak sehat. Arsitektur baru dibangun dengan menggunakan arsitektur CNN dan meningkatkan jumlah layernya, menggunakan layer *dense* dengan intensitas yang tinggi pada tahap *preprocessing*, tidak menggunakan metode *transfer learning*, serta meningkatkan jumlah data *training* dengan augmentasi. Tahap validasi performa model dilakukan dengan mengimplementasikan teknik *k-fold cross validation* dengan matriks evaluasi yang digunakan adalah *accuracy*, *precision*, *recall*, dan *F1-score*. Model Arsitektur Modified CNN yang diajukan berhasil melakukan klasifikasi citra MRI dengan nilai rata-rata F1-score yang tinggi, yaitu sebesar 97%, lebih baik dibandingkan dengan ketiga arsitektur sebelumnya, yaitu 92% untuk Basic CNN, 86% untuk VGG16 Net, serta 85% untuk DenseNet. Model yang dihasilkan dari penelitian tersebut memiliki beberapa kelebihan, di antaranya adalah performa klasifikasi arsitektur Modified CNN yang diajukan dapat diandalkan untuk diagnosis citra MRI tumor otak dengan

nilai akurasi dan *F1-score* yang tinggi dan dapat mengatasi kekurangan yang ada pada ketiga arsitektur lain. Namun, model yang dibangun pada penelitian tersebut masih memiliki beberapa kekurangan, seperti dibutuhkan sumber daya komputasi dengan performa yang tinggi untuk menangani besarnya jumlah parameter, waktu komputasi yang dibutuhkan untuk proses *training* lama, dan juga arsitektur yang dibangun memiliki layer yang kompleks dan membutuhkan data dalam jumlah besar untuk menghindari overfitting.

Penelitian serupa yang menggunakan arsitektur CNN dalam kasus klasifikasi penyakit tumor otak juga pernah dilakukan oleh Sinaga dkk. (2025) yang bertujuan untuk mengatasi permasalahan keterbatasan klasifikasi dan interpretasi manual dari citra MRI tumor otak yang membutuhkan keahlian khusus dan rentan terhadap kesalahan diagnosis. Dataset yang digunakan bersumber dari Kaggle dan memiliki jumlah yang cukup besar sekaligus variatif, yaitu sejumlah 20.672 data citra MRI yang terbagi menjadi empat kelas seperti pada penelitian sebelumnya, yaitu otak *normal*, *meningioma*, *glioma*, dan *pituitary*. Dataset juga akan melewati tahap *preprocessing*, yaitu *grayscale*, *resizing*, dan normalisasi dengan tambahan augmentasi untuk data *training*. Usulan model CNN berbentuk sekuensial sederhana yang terdiri dari *layer* konvolusi, *pooling*, *dense*, dan *dropout* dengan *optimizer* Adam. Inovasi utama pada penelitian tersebut adalah usaha untuk meningkatkan interpretabilitas model dengan mengimplementasikan konsep Explainable AI (XAI) melalui visualisasi, meskipun metode XAI yang digunakan belum dijelaskan secara rinci. Nilai akurasi yang dihasilkan dari model yang dikembangkan sebesar 96% dengan performa generalisasi dan interpretabilitas yang baik. Kedua penelitian tersebut menunjukkan bahwa model yang mengimplementasikan arsitektur CNN dapat menyelesaikan permasalahan klasifikasi citra MRI tumor otak dengan baik sehingga memiliki potensi besar untuk dapat membantu mengoptimalkan proses diagnosis tenaga medis. Performa yang baik dari arsitektur CNN dapat diperoleh dengan membutuhkan data dan sumber daya yang besar serta waktu yang lama sehingga diperlukan adanya metode alternatif yang lebih efisien untuk dapat mengatasi keterbatasan tersebut.

Dalam tahap ekstraksi fitur, salah satu pendekatan yang lebih sederhana tetapi tetap efektif adalah metode berbasis tekstur, seperti Local Binary Pattern (LBP). Pada kasus diagnosis tumor otak, penelitian oleh Kaplan dkk. (2020)

mengimplementasikan konsep ekstraksi fitur LBP untuk mempercepat proses diagnosis sekaligus meningkatkan peluang keselamatan pasien. Selain melakukan klasifikasi tumor otak pasien, fokus pada penelitian ini juga tertuju pada implementasi pendekatan teknik ekstraksi fitur yang merupakan pengembangan teknik LBP klasik, yaitu nLBP dan α LBP. Penelitian ini menggunakan data asli yang bersumber dari Nanfang Hospital dan Tianjin Medical University General Hospital di China sejak tahun 2005 hingga 2010. Dataset terdiri dari citra T1-weighted MRI berukuran 512x512 piksel dengan total 3.064 *slices* dari 233 pasien dan memiliki *ground truth* yang ditentukan secara manual oleh 3 orang ahli radiologi. Sama seperti LBP klasik, teknik nLBP mengekstraksi fitur piksel berdasarkan hubungan antara tetangga piksel yang mengelilinginya dalam 3x3. Nilai setiap digit biner akan diperoleh berdasarkan perubahan nilai piksel tetangga dengan piksel tetangga berikutnya. Sebuah parameter d juga digunakan yang berfungsi untuk menentukan jarak piksel satu dengan piksel selanjutnya yang akan dibandingkan. Sementara itu, fitur dari teknik α LBP diperoleh berdasarkan hubungannya dengan piksel tetangga dalam sudut tertentu, bukan piksel tetangga yang mengelilinginya. Ketiga teknik ekstraksi fitur berbasis LBP tersebut menghasilkan sebuah histogram fitur yang mencerminkan pola yang dimiliki oleh suatu citra. Pola ini digunakan pada tahap klasifikasi, yaitu K-Nearest Neighbor (KNN), Artificial Neural Network (ANN), Random Forest (RF), Averaged One-Dependence Estimators (A1DE), Linear Discriminant Analysis (LDA), dan Support Vector Machine (SVM) dengan menggunakan teknik validasi 10-*fold cross validation* dan matriks evaluasi *accuracy*, *precision*, dan *F-criteria*. Hasil terbaik yang diperoleh dari setiap kombinasi metode ekstraksi fitur dengan arsitektur klasifikasinya adalah nLBP dan KNN dengan akurasi tertinggi sebesar 95.56%. Kombinasi tersebut memiliki hasil yang lebih baik daripada α LBP dengan nilai $\alpha=45$ dan metode klasifikasi KNN di angka 90.57% serta LBP klasik dengan KNN di angka 93.28%. Penelitian ini menunjukkan bahwa model dengan metode ekstraksi fitur berbasis LBP memiliki beberapa kelebihan, seperti beban data dan komputasi yang rendah, sederhana, mudah diaplikasikan, serta *explainable* dengan tetap mempertahankan performa klasifikasi yang dapat diandalkan dalam rangka membantu proses diagnosis tenaga medis.

Metode ekstraksi fitur berbasis LBP yang efisien membutuhkan algoritma klasifikasi yang tepat untuk dapat menghasilkan performa yang optimal, salah

satunya adalah SVM. Seperti pada penelitian yang telah dilakukan oleh Kaplan dkk. (2020), Yang dkk. (2021) juga membuktikan bahwa SVM mampu bekerja dengan baik dalam beban komputasi yang ringan dengan jumlah data yang terbatas, meskipun dengan hasil performa yang masih di bawah CNN. Dalam penelitian tersebut, dilakukan pengembangan model untuk kasus segmentasi citra MRI tumor otak berjenis *low-grade glioma* (LGG) pada dataset yang bersumber dari The Cancer Imaging Archive (TCIA) sejumlah 2.470 citra MRI FLAIR (Fluid-Attenuated Inversion Recovery). Segmentasi dilakukan dengan membandingkan dua metode SVM dan CNN. Pada algoritma SVM, setiap pasien memiliki modelnya masing-masing yang dilatih menggunakan data dari salah satu *slice* citra MRI beserta hasil segmentasi *ground truth* manualnya, sedangkan *slice* lainnya digunakan sebagai data validasi atau *testing*. Data citra yang digunakan telah melalui tahap *preprocessing* dengan *grayscale* dan ekstraksi fitur dengan 7 filter, yaitu Sobel, Gabor, Canny, Gaussian, Median, dan Variance sebelum masuk ke tahap segmentasi. Sementara itu, algoritma CNN menggunakan data citra MRI asli dan *mask* yang telah melalui tahap augmentasi dengan *horizontal flipping* serta rotasi dalam 90, 180, dan 270 derajat. Tahap tersebut menghasilkan total 19.760 citra yang dibagi ke 90% data untuk *training* dan 10% data untuk *testing*. Dari keseluruhan model yang terbentuk, SVM menghasilkan nilai rata-rata akurasi sebesar 93.7% dengan median 97.6% tetapi hanya 67 model dari total 109 model yang berhasil mencapai nilai F1-score lebih dari 0.5. Di sisi lain, model CNN yang dibentuk berhasil memperoleh nilai akurasi sebesar 99.8% dan F1-score sebesar 99.9%. Pada kasus ini, metode CNN terbukti sangat akurat tetapi dengan keterbatasan yang cukup signifikan, seperti memerlukan data yang sangat banyak, waktu *training* yang lama, dan sumber daya komputasi dengan performa yang tinggi. Di sisi lain, metode SVM memiliki nilai akurasi yang lebih rendah dibandingkan dengan CNN serta perlu dibangun sebuah model yang berbeda untuk pasien yang berbeda. Meskipun demikian, metode SVM tetap memiliki beberapa keunggulan dibandingkan dengan metode CNN, seperti kebutuhan data *training* yang lebih ringan, waktu *training* yang jauh lebih cepat, dan hampir tidak memerlukan perangkat dengan spesifikasi yang tinggi. Penelitian tersebut membuktikan bahwa metode SVM masih relevan untuk mengatasi permasalahan pada fasilitas kesehatan yang masih mengalami keterbatasan data, waktu, maupun infrastruktur komputasi.

Penelitian lain mengenai implementasi metode SVM untuk menangani permasalahan segmentasi sekaligus klasifikasi tumor otak juga telah dilakukan oleh Rao dan Karunakara (2022). Penelitian ini bertujuan untuk membantu proses diagnosis manual oleh radiolog yang memakan banyak waktu sekaligus tinggi akan potensi kesalahan dengan mengembangkan model segmentasi dan klasifikasi yang memiliki performa akurasi lebih baik daripada model-model terdahulu. Dataset yang diambil dari tiga sumber digunakan selama proses pengembangan model, yaitu BRATS 2018, 2019, dan 2020 dalam empat tipe citra MRI, yaitu T1, T2, T1C, dan Flair-Ground truth dari total 886 pasien. Pada tahap *pre-processing*, digunakan metode Normalized Median Filtering (NMF) sebagai *blur-removal* yang mampu menghaluskan (*smoothen*) dan menghapus *salt and pepper noise* citra yang impulsif sekaligus tetap mempertahankan nilai fitur tepi (*edge*) melalui penggantian nilai piksel dengan mediannya dalam radius 3x3. Normalisasi juga digunakan dengan melakukan *resize* ke dalam ukuran 256x256. *Binomial thresholding* digunakan sebagai metode segmentasi berdasarkan *threshold* dari nilai mean dan varians histogram probabilitas binomial citra. Tahap ekstraksi fitur tekstur citra menggunakan metode Gray-Level Co-occurrence Matrix (GLCM) yang menentukan hubungan spasial antara dua piksel, yaitu seberapa sering sepasang piksel dengan nilai intensitas tertentu muncul bersama pada jarak dan arah tertentu. Metode GLCM juga dikombinasikan dengan Spatial Grey Level Dependence Matrix (SGLDM) yang melakukan estimasi probabilitas kondisi pasangan dua piksel muncul pada jarak dan arah tertentu. SGLDM memperoleh fitur spasial arah atau jarak dari rata-rata empat arah yang diestimasi pada penelitian ini. Fitur tersebut akan diseleksi menggunakan metode Harris Hawks Optimization (HHO) untuk memilih fitur yang relevan dan membuang fitur yang redundan. HHO melakukan seleksi fitur dengan meniru perilaku *harris hawks bird* dengan menggunakan taktik *surprise pounce* melalui fase eksplorasi dan eksploitasi. Fase eksplorasi dilakukan untuk mencari ruang solusi, sedangkan fase eksploitasi dilakukan untuk mencari solusi terbaik berdasarkan tingkat energi yang diperoleh dari fase transisi di antara kedua fase tersebut. Pencarian solusi pada fase eksploitasi menggunakan beberapa pola dengan tujuan untuk memperoleh hasil yang optimal secara global. Tahap klasifikasi menggunakan konsep dari metode SVM, yaitu Kernel Support Vector Machine (KSVM) yang memanfaatkan *kernel function* untuk memetakan data ke dimensi yang lebih tinggi

menggunakan tiga jenis *kernel*, yaitu *sigmoid*, *linear*, dan RBF dengan optimasi *hyperparameter* menggunakan metode Social Ski Driver (SSD). Selain untuk optimasi, metode SSD juga digunakan untuk menggolongkan jenis tumor ganas (*malignant*) yang muncul menjadi tingkat rendah, sedang, dan tinggi. Berdasarkan tahapan pengembangan model tersebut, hasil performa model yang diperoleh berdasarkan matriks evaluasi *precision*, *recall*, *accuracy*, *F1-score*, dan FNR menunjukkan nilai akurasi tertinggi di angka 99.2%, 99.36%, dan 99.15% untuk masing-masing dataset yang digunakan, melebihi performa yang dihasilkan oleh model-model terdahulu. Hasil ini menunjukkan bahwa dengan kombinasi metode yang tepat, model berbasis SVM yang dalam kasus ini adalah KSVM-SSD dapat memperoleh tingkat akurasi performa deteksi, segmentasi, dan klasifikasi beserta optimasi fitur yang lebih baik dengan kompleksitas komputasi yang tetap efektif dan efisien.

Selain Kaplan (2020) dan Yang (2021), kombinasi metode ekstraksi fitur dan algoritma klasifikasi LBP dan SVM pernah digunakan oleh penelitian terdahulu untuk mengatasi permasalahan di lingkup yang sama, yaitu diagnosis penyakit tumor otak manusia. Penelitian tersebut dilakukan oleh Basthikodi dkk. (2024) yang mengembangkan model dengan mengimplementasikan metode LBP dan Histogram of Oriented Gradients (HOG) untuk ekstraksi fitur, Principal Component Analysis (PCA) untuk reduksi dimensi, serta SVM sebagai algoritma klasifikasi. Dengan menggunakan kombinasi dari tiga dataset yang berbeda dari Kaggle dengan jumlah 7.023 data citra MRI dalam beberapa bidang anatomi, sistem yang dikembangkan dapat mengklasifikasikannya menjadi empat kelas seperti pada penelitian-penelitian sebelumnya, yaitu *glioma*, *meningioma*, *pituitary*, dan *no tumor*. Citra MRI berukuran 64x64 piksel yang telah melewati tahap *preprocessing* berupa *flattening*, augmentasi, normalisasi, dan *histogram equalization* akan masuk ke tahap ekstraksi fitur. Metode LBP mengekstraksi fitur tekstur lokal yang mampu mengatasi variasi pencahayaan citra dalam histogram, sedangkan metode HOG mengekstraksi fitur bentuk dan struktur global dalam vektor gradien. Fitur tersebut memiliki dimensi yang akan direduksi oleh PCA melalui transformasi linear untuk mengurangi overfitting dan meningkatkan efisiensi komputasional dengan tetap mempertahankan 95% variansi data. Berdasarkan matriks evaluasi *accuracy*, *precision*, *recall*, dan *F1-score*, klasifikasi yang dilakukan oleh algoritma SVM saja menghasilkan nilai

akurasi di angka 86.57%. Nilai ini relatif bertambah saat SVM dikombinasikan dengan metode lain, yaitu kombinasi SVM dengan PCA menghasilkan nilai akurasi 94.2%, SVM dengan HOG dan LBP menghasilkan nilai akurasi 95.95%, serta hasil terbaik dari kombinasi SVM dengan HOG, LBP, dan PCA dengan nilai akurasi 96.03%. Kombinasi tersebut menghasilkan performa model dengan yang efisien dan mampu menangani jumlah data yang sedang serta sumber daya yang terbatas, bahkan mampu bersaing dengan model yang lebih kompleks dan berat secara komputasi.

Berdasarkan uraian penelitian-penelitian sebelumnya, dapat disimpulkan bahwa setiap metode dan algoritma memiliki kelebihan dan kekurangannya masing-masing dalam menganalisis citra MRI untuk mengatasi permasalahan diagnosis tumor otak. Ringkasan dan perbandingan dari penelitian-penelitian relevan tersebut yang sekaligus menjadi acuan pada penelitian ini disajikan pada Tabel 2.1.

Tabel 2.1 Tinjauan Pustaka

No	Peneliti & Tahun	Dataset	Ekstraksi Fitur	Algoritma / Model	Hasil	Keterangan
1	Özkaraca dkk. (2023)	Sumber dari Kaggle (Kombinasi figshare, SARTAJ dataset, dan Br35H) dengan total 7.021 citra MRI.	Tidak dilakukan ekstraksi fitur. Klasifikasi langsung menggunakan CNN.	Basic CNN, VGG16 Net, DenseNet, dan Modified CNN.	Modified CNN dengan F1-score 97%., lebih tinggi daripada model lain (92%, 86%, 85%).	+ Performa akurasi dan F1-score tinggi dibanding model lain. - Model membutuhkan performa <i>resource</i> yang tinggi, waktu yang lama, arsitektur yang kompleks, dan data dalam jumlah besar.
2	Sinaga dkk. (2025)	Sumber dari Kaggle dengan total 20.672 citra MRI.	Tidak dilakukan ekstraksi fitur. Klasifikasi langsung menggunakan CNN.	CNN sederhana dan visualisasi hasil untuk Explainable AI (XAI).	Model CNN dengan akurasi 96%.	+ Performa akurasi, generalisasi, dan interpretabilitas model baik. + Implementasi konsep Explainable AI (XAI). - XAI belum dijelaskan secara lebih mendetail dengan metode tertentu. - Jumlah data yang digunakan besar dan waktu <i>training</i> model lama.
3	Kaplan dkk. (2020)	Sumber asli dari Nanfang Hospital dan Tianjin Medical University General Hospital (2005-2010) dengan total 3.064 <i>slices</i> citra T1-weighted MRI.	LBP klasik, nLBP, dan α LBP.	KNN, ANN, RF, AIDE, LDA, dan SVM dengan 10-fold cross validation.	Hasil akurasi terbaik dari setiap metode ekstraksi fitur: • αLBP + KNN: 90.57% • LBP + KNN: 93.28% • nLBP + KNN: 95.56%	+ Dataset asli dan terverifikasi oleh radiolog ahli. + Metode efektif dan efisien dengan performa yang kompetitif dengan <i>deep learning</i>. - Belum berfokus pada eksplorasi lebih lanjut algoritma SVM untuk klasifikasi.

4	Yang dkk. (2021)	Sumber dari TCIA dengan total 2.470 citra MRI FLAIR LGG. Augmentasi menjadi total 19.760 data pada CNN.	Sobel, Gabor, Canny, Gaussian, Median, dan Variance.	Segmentasi SVM dan CNN	Model SVM dengan rata-rata akurasi 93.7% dengan median 97.6% dan model CNN dengan akurasi 99.8% dengan <i>F1-score</i> 99.9%.	+ Kebutuhan data, waktu, dan perangkat SVM jauh lebih ringan daripada CNN. - Perlu dibangun model untuk setiap pasien. - Performa akurasi lebih rendah daripada CNN.
5	Rao dan Karunakara (2022)	Kombinasi BRATS 2018, 2019, dan 2020 dalam empat tipe citra MRI (T1, T2, T1C, dan FLAIR) dari total 886 pasien.	GLCM dan SGLDM dengan seleksi fitur HHO.	KSVM <i>sigmoid</i> , <i>linear</i> , dan RBF dengan optimasi SSD.	Akurasi untuk setiap dataset sebesar 99.2%, 99.36%, dan 99.15%.	+ Performa deteksi, segmentasi, klasifikasi, dan optimasi baik dan efisien. - Metode yang digunakan kompleks dengan banyak tahapan.
6	Basthikodi dkk. (2024)	Kombinasi tiga dataset Kaggle dengan total 7.023 citra MRI dalam beberapa bidang anatomi.	LBP dan HOG dengan PCA untuk reduksi dimensi.	SVM	Akurasi klasifikasi beberapa kombinasi model: • SVM: 86.57% • SVM + PCA: 94.2% • SVM + HOG + LBP: 95.95% • SVM + HOG + LBP + PCA: 96.03%	+ Akurasi yang diperoleh cukup baik meskipun hanya menggunakan metode klasik dan data yang terbatas. - Belum diuji secara langsung dengan model yang lebih kompleks pada dataset yang sama.

BAB III

LANDASAN TEORI

BAB IV

METODOLOGI

BAB V
JADWAL PENELITIAN